



Alineamiento de pares de secuencias



Determinar si una secuencia de nucleótidos o aminoácidos (un gen o una proteína) está relacionada con otra.

Esto nos permite determinar:

- Si evolucionaron desde un ancestro común
- Si tienen funciones comunes
- En el caso de proteínas, si tienen formas similares



Alineamiento de pares de secuencias

Buscamos una “colocación” de las secuencias para que se maximice su **similitud**.

ROJO	
ROSSO	+3
ROUGE	+2
RED	+1

“puntuación” de similitud

ROJ—O
ROSSO
** * +3 (75%)

RO—JO
ROUGE
** +2 (50%)

ROJO
RED—
* +1 (25%)

A las separaciones añadidas artificialmente a una secuencia para maximizar su alineamiento con otra(s) se las denomina **huecos (gaps)** y se denotan por ‘-’.

- Un hueco puede ocurrir en cualquier parte de la secuencia, en el interior o en sus extremos.
- Biológicamente pueden representar mutaciones sufridas durante la evolución.

Similitud: grado de coincidencia entre secuencias.

- ✓ Es una característica cuantitativa, podremos decir por ejemplo “el grado de similitud entre dos secuencias es de un 45%”



Los alineamientos pueden ser:

- **Alineamiento global:** las secuencias se alinean a lo largo de toda su longitud, intentando alinear secuencias completas
 - ✓ Se introducen huecos para igualar las longitudes de secuencia.
 - ✓ Útil para secuencias muy parecidas y de longitud similar.
- **Alineamiento local:** sólo se alinean las partes más parecidas de la secuencia
 - ✓ Favorece encontrar patrones similares dentro de la secuencia.
 - ✓ Un alineamiento local es una combinación de muchos alineamientos globales de secuencias cortas.



Algoritmos de alineamiento



Vamos a necesitar **métodos heurísticos** para llevar a cabo estos alineamientos ya que las secuencias son largas y la cantidad de combinaciones posibles muy alta.

- Diagrama de puntos (dot plots)
- Algoritmos dinámicos
 - ✓ Alineamiento global: Needleman and Wunsch (1970)
 - ✓ Alineamiento local: Smith and Waterman (1981)

Heurísticas: estrategias o reglas empíricas para resolver el problema de forma aproximada. Se utilizan cuando el tiempo o los recursos son limitados, o cuando no hay una solución óptima conocida.



- Es un método visual
- No requiere de computación
- No requiere hipótesis biológicas

Se coloca una secuencia en el eje X y otra en el eje Y. En cada lugar donde las secuencias coinciden se dibuja un punto.

Las secuencias similares aparecerán en forma de líneas diagonales

TCCGTCCATTGATTACAAAGTCC



TCCGACTTGAGATTACAGAAGTCG

Cada vez que haya una coincidencia en un nucleótido, colocamos un punto.

Por ejemplo, en el caso del primer nucleótido de la secuencia horizontal (T)



TCCGTCCATTGATTACAAAAGTCC




TCCGACTTGAGATTACAGAAGTCG

El número de repeticiones de un patrón viene dado por el número de diagonales por arriba o por abajo. Ej. el patrón **TCC** se repite 3 veces

Por ejemplo, siguiendo desde la primera, segunda y última coincidencia...

Se suele establecer un tamaño de ventana mínimo, un umbral para el número de nucleótidos, ej. 3.

Se suelen sustituir los puntos por líneas.






Queremos el mejor alineamiento de todos los posibles, aquel que proporcione una “puntuación” de similitud mayor.

El número de posibles alineamientos permitiendo huecos para dos secuencias de longitud n es el número combinatorio $\binom{2n}{n}$, las combinaciones sin repetición de un conjunto de $2n$ elementos tomados en grupos de n . En secuencias pequeñas, por ejemplo, de 30 bases, tendríamos 10^{17} combinaciones.

Utilizamos **programación dinámica**: dividimos el problema en subproblemas, de manera que la solución a estos subproblemas simplifica la solución del problema global.



Los algoritmos dinámicos funcionan en base a un sistema de puntuaciones de cuán parecidas son dos secuencias.

Un sistema de puntuación sencillo podría ser:

- +1 por cada elemento igual (match)
- -1 por cada elemento desigual (mismatch)
- -1 por cada hueco introducido (gap)

```
G-ATESLIKESCHEESE
|  |||           |||||
GRATED-----CHEESE
```

Puntuación: 10 matches * 1 + 1
mismatch * (-1) + 6 gaps * (-1) = 3



Creamos una matriz, con una secuencia en horizontal y la otra en vertical.
En la primera fila y columna tenemos valores de distancia al origen (gap scores)

		C	O	E	L	A	C	A	N	T	H
P	0	← -1	← -2	← -3	← -4	← -5	← -6	← -7	← -8	← -9	← -10
E	↑ -1										
L	↑ -2										
I	↑ -3										
C	↑ -4										
A	↑ -5										
N	↑ -6										
	↑ -7										



A cada celda se le asigna una puntuación de la siguiente forma:

- Se calcula el MM (match/mismatch) de la celda.
Ej $P \neq C$ entonces $MM = -1$
- Se calculan 3 sumas:
 - ✓ $MM + \text{celda superior izquierda: } -1 + 0 = -1$
 - ✓ $MM + \text{celda izquierda: } -1 - 1 = -2$
 - ✓ $MM + \text{celda superior: } -1 - 1 = -2$
- El valor asignado a esa celda será el máximo.
- También se le asigna la dirección que corresponda a ese valor.
- Debe existir un criterio de desempate para resolver los empates.

$P \neq C \rightarrow MM = -1$
 $\xrightarrow{\text{green arrow}}$
 $0 - 1 = -1$
 $-1 - 1 = -2$
 $-1 - 1 = -2$

		C	O	E	L	A	C	A	N	T	H
P	0	← -1	← -2	← -3	← -4	← -5	← -6	← -7	← -8	← -9	← -10
E	↑ -1	↖ -1	↖ -2	↖ -3	↖ -4	↖ -5	↖ -6	↖ -7	↖ -8	↖ -9	↖ -10
L	↑ -2	↖ -2	↖ -2	↖ -1	↖ -2	↖ -3	↖ -4	↖ -5	↖ -6	↖ -7	↖ -8
I	↑ -3	↖ -3	↖ -3	↖ -2	↖ 0	↖ -1	↖ -2	↖ -3	↖ -4	↖ -5	↖ -6
C	↑ -4	↖ -4	↖ -4	↖ -3	↖ -1	↖ -1	↖ -2	↖ -3	↖ -4	↖ -5	↖ -6
A	↑ -5	↖ -3	↖ -4	↖ -4	↖ -2	↖ -2	↖ 0	↖ -1	↖ -2	↖ -3	↖ -4
N	↑ -6	↖ -4	↖ -4	↖ -5	↖ -3	↖ -1	↖ -1	↖ 1	↖ 0	↖ -1	↖ -2
	↑ -7	↖ -5	↖ -5	↖ -5	↖ -4	↖ -2	↖ -2	↖ 0	↖ 2	↖ 1	↖ 0



Seguimos la ruta con la mejor puntuación (trace-black):

- Comenzando en la esquina inferior derecha
- Siguiendo las flechas:
 - ← desplazamiento de la cadena vertical (eje Y) respecto de la horizontal (eje X).
 - ↑ desplazamiento de la horizontal respecto a la vertical.
 - ↖ no hay desplazamiento.

		C	O	E	L	A	C	A	N	T	H
P	0	←-1	←-2	←-3	←-4	←-5	←-6	←-7	←-8	←-9	←-10
E	↑-1	↖-1	↖-2	↖-3	↖-4	↖-5	↖-6	↖-7	↖-8	↖-9	↖-10
L	↑-2	↖-2	↖-2	↖-1	←-2	←-3	←-4	←-5	←-6	←-7	←-8
I	↑-3	↖-3	↖-3	↑-2	↖-1	←-1	←-2	←-3	←-4	←-5	←-6
C	↑-4	↖-4	↖-4	↑-3	↑-1	↖-1	↖-2	↖-3	↖-4	↖-5	↖-6
A	↑-5	↖-3	←-4	↑-4	↑-2	↖-2	↖-1	←-1	←-2	←-3	←-4
N	↑-6	↑-4	↖-4	↖-5	↑-3	↖-1	↑-1	↖-1	←-1	←-1	←-2
	↑-7	↑-5	↖-5	↖-5	↑-4	↑-2	↖-2	↑-0	↖-2	←-1	←-0

COELACANTH
-PELICAN--



Global

- Útiles cuando las secuencias tienen un tamaño muy parecido.
- Un alineamiento local hace múltiples alineamientos globales sobre subsecuencias.

Local

- Útil con secuencias de distinto tamaño pero que se espera que tengan regiones comunes.
- Los algoritmos tienen un coste computacional más alto.

Global

FTFTALILLAVAV

F--TAL-LLA-AV

Local

FTFTALILL-AVAV

--FTAL-LLAAV--



Modificación del algoritmo de Needleman-Wunsch

1. La matriz se construye igual excepto que:

- La primera fila y columna son 0s, en vez de -1,-2,-3,-4...
- Mismatch es -1 y match 1.
- Si algún valor de celda es negativo, lo ponemos a 0.

2. El trace-back comienza en la puntuación más alta y termina cuando llegue a un 0.

COELACANTH
-PELICAN--

		C	O	E	L	A	C	A	N	T	H
P	0	0	0	0	0	0	0	0	0	0	0
E	0	1	0	0	0	0	0	0	0	0	0
L	0	0	0	2	0	1	0	0	0	0	0
I	0	0	0	0	1	1	0	0	0	0	0
C	0	1	0	0	0	0	2	1	0	0	0
A	0	0	0	0	0	1	1	3	2	1	0
N	0	0	0	0	0	0	0	2	4	3	2

1 O vs E $\rightarrow -1 + \max(0,0,0) \rightarrow -1 \rightarrow 0$

2 L vs L $\rightarrow 1 + \max(0,1,0) \rightarrow 2$

Matrices de sustitución



- Dos nucleótidos pueden o ser iguales o diferentes, pero en el caso de los aminoácidos la situación es más compleja.
- Dos aminoácidos pueden ser iguales, diferentes o más o menos parecidos. Por ejemplo, un aminoácido neutro se parecerá más a otro aminoácido neutro que a uno ácido.
- Una forma de cuantificar el parecido entre diferentes aminoácidos es estudiar **cuantas veces suelen aparecer en la misma posición en proteínas homólogas**. Si los dos aminoácidos suelen aparecer en las mismas posiciones debe ser porque **funcionalmente son** más **equivalentes** que dos aminoácidos que no suelen aparecer en las mismas posiciones.



- En estas **matrices de sustitución o de puntuación** se representa la frecuencia con la que un aminoácido es sustituido por otro en proteínas homólogas.
- Se estiman probabilidades de sustitución basadas en datos empíricos de alineamientos de secuencias reales.
- Es común su representación mediante números enteros multiplicándolos antes por un factor de escala, para que sea más fácil su uso en los algoritmos de alineamiento.
- Puntuación basada en similitud funcional y estructural. Se asignan valores más altos a sustituciones entre aminoácidos con propiedades similares (ej., cargas eléctricas, tamaño, polaridad).
- Dependiendo del experimento con el que se realiza la estimación de la probabilidad de sustitución tendremos distintos tipos de matrices de sustitución.
 - PAM: Calcula cambios acumulados a lo largo del tiempo en alineamientos globales de proteínas estrechamente relacionadas.
 - BLOSUM: Se basa en alineamientos locales y agrupa secuencias según su similitud.



1978: Dayhoff et al. estudiaban el modelo evolutivo de los cambios en los aminoácidos de las proteínas.

- Evaluaron 1572 sustituciones en 71 grupos de proteínas.
- En cada grupo las secuencias compartían más del 85% de similitud.
- Calcularon la frecuencia de los cambios para todas las combinaciones posibles de 2 aminoácidos.

El cambio de un aminoácido por otro se denominó 'mutación puntual aceptada' (**PAM**, Accepted Point Mutation).



- La **matriz PAM1** se construye de forma que cada elemento de la matriz M_{ij} cuantifica la probabilidad de que un aminoácido i sea remplazado por otro aminoácido j en el intervalo evolutivo de 1 PAM.
- **1 PAM** se define como el intervalo evolutivo en que cambia un 1% de los aminoácidos en el alineamiento de 2 secuencias (1 cambio o PAM por cada 100 aminoácidos).
- La matriz PAM1 se puede multiplicar por sí misma para calcular matrices de N PAMs: probabilidades de sustitución si hay un N% de probabilidades de que cada aminoácido de la cadena haya mutado.

- lod score PAM250

- *Lod (log odd) score*: puntuación del logaritmo de la frecuencia de sustitución de un aminoácido por otro.



1992: Henikof y Henikof mejoran la matriz de Dayhoff con una base de datos de 500 alineamientos entre proteínas poco parecidas entre sí.

BLOcks amino acid **SU**bstitution **M**atrices se construyen a partir de la base de datos BLOCKS, que contiene “segmentos alineados sin huecos, correspondientes a las regiones de proteínas más conservadas” (que se llaman bloques). Inicialmente contenía 500 patrones.

- Cada matriz BLOSUM indica un % de similitud en las secuencias de partida. BLOSUM45, BLOSUM62, BLOSUM80,...
- Para definir diferentes matrices BLOSUM se establecen umbrales de similitud, agrupando las secuencias con una similitud mayor o igual al valor del umbral.

Por ejemplo, para calcular la matriz BLOSUM62 se agruparon las proteínas con similitud mayor o igual que 62%.

Matrices de sustitución: BLOSUM

- Con los bloques de secuencias alineadas se calcula una tabla de frecuencias de cada pareja de aminoácidos alineados, obteniendo 210 parejas posibles con sus respectivas frecuencias de aparición que permitirán calcular $R_{ij} = \frac{q_{ij}}{e_{ij}}$ donde q_{ij} son las frecuencias observadas y e_{ij} las esperadas.

En las matrices se representa

$$S_{ij} = \log_2(R_{ij})$$

[illegible]



PAM

- PAM1, PAM10, PAM100 → Para comparar **secuencias muy similares** (cercanas evolutivamente).
- PAM250 → Para secuencias más **distantes**, con muchas mutaciones acumuladas.
- Útil para alineamientos globales, ya que modela mutaciones a lo largo del tiempo.
- Mejor para estudiar relaciones evolutivas lejanas, ya que se basa en modelos de cambio a largo plazo.

BLOSUM

- BLOSUM80, BLOSUM90 → Para secuencias muy parecidas.
- BLOSUM62 → Equilibrio entre sensibilidad y precisión, una de las más usadas.
- BLOSUM45 → Para secuencias muy divergentes.
- Útil para alineamientos locales, ya que se centra en encontrar similitudes dentro de fragmentos específicos.
- Mejor para buscar regiones conservadas en secuencias que pueden haber divergido significativamente.

¿Por qué no hablamos de matrices de puntuación para DNA?

Normalmente el alineamiento de proteínas nos da más información:

- Muchos cambios de un nucleótido de un codón no varían el aminoácido resultante: "más estable".
- Muchos aminoácidos comparten propiedades biofísicas.
- Muchas proteínas comparten estructura o regiones estructurales.
- El DNA sufre distintas modificaciones pos-traduccionales que pueden influir en la proteína que codifica.

No obstante también existen matrices de sustitución para nucleótidos

	A	T	C	G
A	4	-5	-5	-5
T	-5	4	-5	-5
C	-5	-5	4	-5
G	-5	-5	-5	4

Matriz utilizada
por BLAST

	A	T	C	G
A	2			
T	-7	2		
C	-7	-5	2	
G	-5	-7	-7	2

Matriz PAM1 para nucleótidos

La transición (mutación entre purinas A-G, o entre pirimidinas C-T) es más común que la transversión (de purina a pirimidina)