



## Lab1. Introducción a R

### Ejercicio propuesto

En 1999, Golub y colaboradores (Golub et al. 1999) publicaron un estudio sobre leucemia que representó una de las primeras aplicaciones de la tecnología de microarrays para fines de diagnóstico. En aquel momento, no se realizaba ninguna prueba diagnóstica que ayudara a distinguir entre leucemia mieloide aguda (AML) y leucemia linfoblástica aguda (ALL). En este trabajo, Golub trataba de investigar si el perfil de expresión génica podría ser una herramienta útil para hacer esta clasificación. Utilizaron microarrays de DNA de Affymetrix para medir el nivel de expresión de 7129 genes en niños con leucemia aguda en los que se conocía el tipo. El objetivo del estudio fue desarrollar un procedimiento para distinguir entre AML o ALL a partir de los niveles de expresión génica de un paciente. Específicamente se trataba de abordar dos cuestiones importantes:

1. ¿Qué genes son los más informativos? Si un gen se expresa diferencialmente entre individuos con cada tipo de leucemia, el nivel de expresión de ese gen puede ser informativo a la hora de diagnosticar el tipo de leucemia.
2. ¿Cómo se puede predecir el tipo de leucemia a partir de los datos de expresión? El perfil de expresión de un individuo son sus niveles de expresión en un grupo de genes. Buscamos un perfil que nos permita traducir los datos de expresión en una predicción del tipo de leucemia.

Los datos `golub.dat` contienen los niveles de expresión de 72 pacientes, 62 de ellos se utilizarán para identificar los genes informativos o diferencialmente expresados y los otros 10 para comprobar lo buena o mala que es la estrategia de predicción.

Además de la cantidad de expresión de cada uno de los genes se recogen las siguientes variables,

| Variable  | Descripción                                                                                                                                                                                                                         |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Samples   | Identificador del individuo, único para cada paciente                                                                                                                                                                               |
| BM.PB     | Tipo de tejido del que se ha conseguido extraer el perfil génico. Puede tomar dos valores BM para médula espinal y PB para sangre periférica.                                                                                       |
| Gender    | Sexo del individuo. Puede tomar dos valores M para varones y F para mujeres.                                                                                                                                                        |
| Source    | Hospital donde se trata al paciente.                                                                                                                                                                                                |
| tissue.mf | Combinación de las variables BM.PB y Gender.                                                                                                                                                                                        |
| cancer    | Tipo de leucemia. Puede tomar tres valores: aml para leucemia aguda mieloide, allB para leucemia aguda linfoblástica con origen en células B y allT para leucemia aguda linfoblástica con origen en células T.                      |
| gr        | Grupo de muestra. Puede tomar dos valores: train para indicar los 62 individuos utilizados en la identificación de los genes diferencialmente expresados y test para indicar los 10 individuos utilizados en la fase de predicción. |

Cargamos los datos en R utilizando el código,

```
golub <- read.table("golub.dat", header=TRUE, sep = "\t")
```

## Identificar los genes informativos

Nuestro conjunto de datos (`data.frame`) tiene 7136 variables. Podemos consultar el nombre de las variables con la función `colnames()`,

```
head(colnames(golub),n=50)
```

Utilizamos la función `head()` para mostrar una lista de `n=50` elementos del vector de nombres. Notad que las 7 primeras variables son variables clínicas (metadatos o variables fenotípicas). Si queremos obtener un listado con los identificadores de los genes que se han medido,

```
colnames(golub)[-1:7]
```

Aunque este conjunto de datos es pequeño en relación al tamaño que se maneja en estos momentos en el ámbito de la expresión génica, vamos a simplificar esta primera parte, examinando una muestra aleatoria de 100 genes para todos los pacientes en el grupo ‘train’ del data frame `golub`. Para manejar todos la misma muestra vamos a hacer esta selección con el siguiente código,

```
# establecemos una semilla para poder reproducir los resultados
set.seed(2022)
# creamos un vector con los genes seleccionados
# sin reemplazamiento para no repetir genes!
gene.selected <- sample(colnames(golub)[-1:7], size = 100, replace = FALSE)

# creamos una data frame con los genes seleccionados
# variables: las 7 primeras variables y los genes seleccionados
# individuos: los 62 que tienen el valor train en la variable gr
golub.train <- golub[golub$gr== "train", c(colnames(golub)[1:7],gene.selected)]
# comprobamos las dimensiones de este data frame
dim(golub.train)

# creamos una matriz numérica únicamente con los genes
gene.matrix.sample <- as.matrix(golub.train[ , -1:7])
class(gene.matrix.sample)
```

Con la función `class()` obtenemos el tipo de objeto R, en este caso una matriz (`matrix`).

Notad que `gene.matrix.sample` no es exactamente una matriz de expresión, sino su traspuesta. En la matriz de expresión, los genes se presentan por filas y las muestras por columnas.

1. Construye un histograma que muestre la distribución de la expresión del primer gen. Describe la forma de esta distribución.
2. Crea un vector lógico, `leuk.type`, que tenga el valor `TRUE` para la leucemia de tipo AML y `FALSE` en caso contrario, es decir si la variable `cancer` toma los valores `allT` o `allB`. ¿Cuántos pacientes hay de cada tipo en esta muestra? Utiliza la función `factor()` para convertir este vector lógico en un factor con dos niveles `ALL` y `AML`.
3. El *perfil de expresión* de un gen son los valores que tendremos en ese gen en todas las muestras consideradas. Muestra el perfil de expresión del primer gen. Represéntalo en un diagrama de dispersión utilizando diferentes colores para indicar el tipo de leucemia.

4. Calcula el nivel medio de expresión para cada uno de los genes en cada grupo de leucemia. Utiliza la función `apply()` que repite una operación para cada fila o columna de una matriz. Almacena los resultados en dos vectores, `aml.mean.expression` para los pacientes con AML, y `all.mean.expression` para los pacientes con ALL.

a) Representa en un diagrama de dispersión las medias de ALL (abscisas) frente a las medias AML (ordenadas).

5. Para cada gen, compara la expresión promedio entre pacientes con AML y pacientes con ALL. Para ello, calcula las diferencias en el nivel de expresión promedio y almacénalo en el vector `diff.mean.expression`.

a) ¿Cuál es la diferencia de expresión media para el gen que ocupa la primera posición en la lista entre los dos tipos de leucemia? ¿En cuál de los dos tipos de paciente está sobre-expresado este gen? Teniendo en cuenta esta diferencia, ¿podrías decir, sin utilizar más información, que este gen es un gen informativo para la identificación del tipo de leucemia?

b) Describe la distribución de las diferencias en los niveles medios de expresión utilizando herramientas numéricas y gráficas. Describe esta distribución. Puedes contestar ahora si es esperable que el primer gen de la lista sea un gen informativo para la identificación del tipo de leucemia.

6. Vamos a identificar los outliers para la diferencia de niveles de expresión promedio. Estos outliers serán los genes que muestran diferencias más extremas y por tanto los genes a priori más informativos. Identificamos los outliers utilizando el criterio de los cuartiles utilizado en los diagramas de cajas. El siguiente código permite identificar los valores extremos por arriba, es decir por diferencias extremadamente grandes.

```
# calculamos el primer y tercer cuartil
quart.1 <- quantile(diff.mean.expression, 0.25, na.rm = TRUE)
quart.3 <- quantile(diff.mean.expression, 0.75, na.rm = TRUE)

# rango intercuartílico
iqr <- quart.3 - quart.1 # o el comando IQR(diff.mean.expression)

# definimos los límites para determinar los outliers
lb.outlier <- quart.1 - 1.5*iqr # inferior
ub.outlier <- quart.3 + 1.5*iqr # superior

# lista de los outliers por arriba (expresión > límite superior)
large.out <- (diff.mean.expression > ub.outlier)
diff.mean.expression[large.out]

# ordenados de mayor a menor
sort(diff.mean.expression [large.out], decreasing = TRUE)
```

a) ¿Cuáles son los valores de los límites superior e inferior?

b) ¿Cuántos genes son outliers por tener diferencias en los niveles de expresión promedio extremadamente altos?

c) Encuentra los outliers por tener diferencias en los niveles de expresión promedio extremadamente bajos. ¿Cuántos outliers hay de este tipo?

d) ¿Cuál es el gen más informativo sobre-expresado para el tipo de leucemia AML? ¿Y el sobre-expresado para el tipo ALL? Podeis utilizar las funciones `which.max()` y `which.min()` para obtener las posiciones del mayor y menor elemento del vector que se les pasa como argumento, respectivamente.

e) Entonces, retomando la cuestión de interés, el primer gen de nuestra muestra, ¿será un gen informativo para la identificación del tipo de leucemia?

7. Hasta aquí hemos identificado los genes informativos en una muestra de 100 genes. Modifica ligeramente el código para obtener los genes informativos de los 7129 genes analizados en el estudio original. El punto de partida será la matriz de expresión de los genes,

```
gene.matrix <- as.matrix(golub[golub$gr== "train",- (1:7)])
```


y el vector lógico calculado anteriormente como,

```
leuk.type <- (golub.train$cancer == "aml")
```

## Predecir el tipo de leucemia

La estrategia que utilizó Golub y colaboradores para predecir el tipo de leucemia a partir de los datos de expresión fue la siguiente. Para cada individuo en el grupo test se compara el nivel de expresión de cada uno de los genes identificados como informativos, con el nivel promedio de dicho gen para pacientes de tipo AML y de tipo ALL en el grupo train, denotados como  $\mu_{AML}$  y  $\mu_{ALL}$ , respectivamente. Un gen determinado vota por AML o ALL, dependiendo de si su nivel de expresión está más cerca de  $\mu_{AML}$  o  $\mu_{ALL}$ . El paciente se clasifica en el tipo que más votos obtenga en todos los genes identificados como informativos. La siguiente figura representa un ejemplo de este sistema de votación en un paciente. La flecha es el nivel de expresión del paciente y los extremos de las cajas representan los niveles de expresión promedio en cada tipo del grupo train, es decir,  $\mu_{AML}$  y  $\mu_{ALL}$ . El gen 1 vota por el tipo ALL, puesto que su nivel de expresión está más cerca de  $\mu_{ALL}$ . El gen 3 vota por AML puesto que su nivel de expresión está más cerca de  $\mu_{AML}$ .

Los votos no serán dicotómicos, sino que se ponderan para tener en cuenta cómo de lejos estamos del punto medio entre los dos tipos (línea de puntos vertical). Pesará más el voto que se encuentre más lejos de este punto. Así, el voto del gen 2 (v2) no es tan claro como el voto del gen 1 (v1) por el tipo ALL, por lo que v1 será mayor que v2. Para asignar finalmente el paciente a un tipo de leucemia, se suman todos los votos, ganando el tipo que obtenga una mayor puntuación.



En el artículo original utilizaron 50 genes informativos para hacer esta clasificación. Por simplicidad, nosotros sólo vamos a utilizar los 10 genes más atípicos en la diferencia entre las medias de expresión de AML y ALL, 5 atípicos por arriba y 5 por abajo. Se va a utilizar la expresión en estos 10 genes en los pacientes del grupo test para hacer la predicción del tipo de leucemia.

Lo primero es crear el `data.frame` con el conjunto de datos del grupo 'test',

```
golub.test <- golub[golub$gr== "test", ]
```

Los 10 genes más informativos (apartado 7) son,

```
inf.genes <- c("M19507_at", "M27891_at", "M11147_at", "M96326_rna1_at", "Y00787_s_at",
               "M14483_rna1_s_at", "X82240_rna1_at", "X58529_at", "M33680_at", "U05259_rna1_at")
```

Recordad que podemos acceder a las columnas de un data frame (o matriz) por sus nombres, así el comando `golub.test[ , inf.genes]` devolverá la expresión de los genes informativos del data frame `golub.test`.

8. Calcular  $\mu_{AML}$  y  $\mu_{ALL}$  para cada gen informativo en el data frame `golub.train`. Almacenamos estos resultados en los vectores `mu.ALL` y `mu.AML`. ¿Cuáles son los valores de estas medias para el primer gen informativo?

9. Utiliza el siguiente código para determinar la dirección del voto de cada uno de los genes en los 10 pacientes del grupo test. El valor 0 representa el voto para AML y 1 para ALL. Usamos dos bucles `for` y una estructura condicional `if` para asignar las direcciones del voto de cada uno de los 10 genes informativos y cada uno de los 10 pacientes del grupo test.

```
# creamos la matriz con la expresión de los genes informativos
test.gene.matrix <- golub.test[, inf.genes]
# creamos una matriz vacía, votes, en la que almacenaremos los votos
num.genes <- ncol(test.gene.matrix)
num.patients <- nrow(test.gene.matrix)
votes <- matrix(nrow = num.patients, ncol = num.genes)
# calculamos la dirección y distancia para cada gen
dist.from.aml <- vector("numeric", num.genes)
dist.from.all <- vector("numeric", num.genes)

# repetir desde 1 hasta el nº de filas de votes (paciente)
for(i in 1:dim(votes)[1]){
  # repetir desde 1 hasta el nº de columnas de votes (genes)
  for(j in 1:dim(votes)[2]) {
    # distancias a mu del paciente i (valor absoluto: abs)
    dist.from.aml[i] <- abs(test.gene.matrix[i, j] - mu.aml[j])
    dist.from.all[i] <- abs(test.gene.matrix[i, j] - mu.all[j])
    if(dist.from.aml[i] <= dist.from.all[i]){
      votes[i, j] <- 0 # 0 si la distancia a mu.AML <= que a mu.ALL
    } else { votes[i, j] = 1 # 1 en otro caso
    }
  }
}
```

a) Almacenamos los resultados en una matriz llamada `votes`. ¿Cuáles son las dimensiones de esta matriz? Cada fila de esta matriz, ¿contiene los votos de un paciente o los votos de un gen?

b) Los dos vectores `dist.from.aml` y `dist.from.all` almacenan las distancias entre la expresión en el paciente y las medias para los tipos AML y ALL respectivamente. Esta distancia se calcula

como el valor absoluto de la diferencia. Se necesitan dos bucles `for`, uno que varía el índice `i` desde 1 hasta 10 y el otro que varía `j` desde 1 hasta 10 también.

i) Cuando `i=1` y `j=1`, describe los cálculos que se realizan y almacenan en `dist.from.aml` y `dist.from.all`.

ii) ¿Qué se calcula y almacena cuando `i=2` y `j=1`?

iii) ¿Qué se calcula y almacena cuando `i=1` y `j=2`?

c) Observa los resultados de la primera fila de la matriz `votes`, del primer paciente. ¿Cuáles son los genes para este paciente que votan por el tipo AML y cuales votan por el tipo ALL?

10. Calcula `v1, ..., v10`, como las desviaciones del punto medio entre las dos medias. El siguiente código almacena estas desviaciones en una matriz llamada `deviation.magnitude`.

```
deviation.magnitude <- matrix(nrow = num.patients, ncol = num.genes)
for(i in 1:dim(deviation.magnitude)[1]){
  for(j in 1:dim(deviation.magnitude)[2]) {
    midpoint <- (mu.aml - mu.all)/2
    deviation.magnitude[i,j] <- abs(test.gene.matrix[i, j] - midpoint[j])
  }
}
# añadimos los genes como nombre de columna
colnames(deviation.magnitude) <- colnames(test.gene.matrix)
```

a) ¿Cuál es la desviación del gen 'M19507\_at' para el paciente 1? ¿Qué paciente es el que tiene una desviación mayor en este gen?

b) Para el paciente 1, ¿qué desviaciones deberían sumarse para calcular el voto total para el tipo AML?

11. Calcular VAML y VALL para cada paciente del grupo test como la suma de las desviaciones de los genes que votan por cada uno de los tipos. Determinamos el tipo de cada paciente como el tipo cuyo voto sea mayor. El código es el siguiente,

```
# sumamos las desviaciones que correspondan
V.aml <- vector("numeric", num.patients)
V.all <- vector("numeric", num.patients)
for(i in 1:num.patients){
  V.aml[i] <- sum(deviation.magnitude[i, which(votes[i,] == 0)])
  V.all[i] <- sum(deviation.magnitude[i, which(votes[i,] == 1)])
}
# el tipo de leucemia para cada paciente
predicted.leuk.type <- vector("numeric", num.patients)
for(i in 1:num.patients){
  if (V.aml[i] > V.all[i]){predicted.leuk.type[i] = "aml"}
  if (V.aml[i] < V.all[i]){predicted.leuk.type[i] = "all"}
  if (V.aml[i] == V.all[i]){predicted.leuk.type[i] = "tie"}
}
predicted.leuk.type
```

a) Describe brevemente como el primer bucle `for` crea los vectores `V.aml` y `V.all`.

b) Describe brevemente como el segundo bucle `for` y la sentencia condicional `if` crea el vector `predicted.leuk.type`.

**12.** Comprueba la precisión de la predicción del tipo de leucemia comparando dicha predicción con el tipo real almacenado en la variable `cancer`. Da alguna medida que permita evaluar como de buena es esta predicción.

## Referencias

Golub, Todd R, Donna K Slonim, Pablo Tamayo, Christine Huard, Michelle Gaasenbeek, Jill P Mesirov, Hilary Coller, et al. 1999. "Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring." *Science* 286 (5439): 531–37.