R Lab5. Alineamiento múltiple con R

Bioinformática. Ingeniería Biomédica

Vamos a utilizar el paquete `msa` de Bioconductor para llevar a cabo el alineamiento de múltiples secuencias. Este paquete implementa diferentes algoritmos como ClustalW (Thompson, Higgins, and Gibson 1994), ClustalOmega (Sievers et al. 2011) y MUSCLE (Edgar 2004a), (Edgar 2004b).

Instalación

El paquete `msa` esta disponible en Bioconductor. Lo instalamos y cargamos,

```
if(!("msa" %in% installed.packages()))
  BiocManager::install("msa")
library("msa")
```

Cargamos también el paquete `Biostrings` de Bioconductor.

```
if(!("Biostrings" %in% installed.packages()))
  BiocManager::install("Biostrings")
library("Biostrings")
```

Un primer alineamiento múltiple

Vamos a hacer nuestro primer alineamiento múltiple utilizando un fichero de ejemplo, en formato FASTA, incluido en el mismo paquete `msa`, el fichero `exampleAA.fasta`. Para obtener el fichero podemos utilizar la función `system.file()` para obtener la ruta completa de este archivo,

```
mySequenceFile <- system.file("examples", "exampleAA.fasta", package="msa")
mySequenceFile
```

```
## [1] "C:/stat/R-4.3.3/library/msa/examples/exampleAA.fasta"
```

Utilizamos la función `readAAStringSet()` del paquete `Biostrings` para leer el fichero y crear un objeto de la clase `XStringSet`. En este caso y puesto que la secuencia es de aminoácidos, será un objeto de tipo `AAStringSet`.

```
mySequences <- Biostrings::readAAStringSet(mySequenceFile)
mySequences
```

```
## AAStringSet object of length 9:
##     width seq                                               names
## [1]   452 MSTAVLENPGLGRKLSDFGQETS...LKILADSINSEIGILCSALQKIK PH4H_Homo_sapiens
## [2]   453 MAAVVLENGVLSRKLSDFGQETS...KILADSINSEVGILCNALQKIKS PH4H_Rattus_norve...
## [3]   453 MAAVVLENGVLSRKLSDFGQETS...KILADSINSEVGILCHALQKIKS PH4H_Mus_musculus
## [4]   297 MNDRADFVVPDITTRKNVGLSHD...DVAPDDLVLNAGDRQGWADTEDV PH4H_Chromobacter...
## [5]   262 MKTTQYVARQPDDNGFIHYPETE...MALVHEAMRLGLHAPLFPPKQAA PH4H_Pseudomonas_...
## [6]   451 MSALVLESRALGRKLSDFGQETS...LKILADSISSEVEILCSALQKLK PH4H_Bos_taurus
## [7]   313 MAIATPTSAAPTPAPAGFTGTLT...DVVDGDAVLNAGTREGWADTADI PH4H_Ralstonia_so...
## [8]   294 MSGDGLSNGPPPGARPDWTIDQG...AVLTRGTQAYATAGGRLAGAAAG PH4H_Caulobacter_...
## [9]   275 MSVAEYARDCAAQGLRGDYSVCR...QTADFEAIVARRKDQKALDPATV PH4H_Rhizobium_loti
```

La función `msa()` hará un alineamiento múltiple, por defecto con el algoritmo *ClustalW*. Dejamos los parámetros por defecto.

```
myFirstAlignment <- msa(mySequences)
```

```
## use default substitution matrix
```

```
myFirstAlignment
```

```
## CLUSTAL 2.1
##
## Call:
##    msa(mySequences)
##
## MsaAAMultipleAlignment with 9 rows and 456 columns
##     aln                                                names
## [1] MAAVVLENGVLSRKLSDFGQETSYIE...QLKILADSINSEVGILCNALQKIKS PH4H_Rattus_norve...
## [2] MAAVVLENGVLSRKLSDFGQETSYIE...QLKILADSINSEVGILCHALQKIKS PH4H_Mus_musculus
## [3] MSTAVLENPGLGRKLSDFGQETSYIE...QLKILADSINSEIGILCSALQKIK- PH4H_Homo_sapiens
## [4] MSALVLESRALGRKLSDFGQETSYIE...QLKILADSISSEVEILCSALQKLK- PH4H_Bos_taurus
## [5] --------------------------...LNAGDRQGWADTEDV---------- PH4H_Chromobacter...
## [6] --------------------------...LNAGTREGWADTADI---------- PH4H_Ralstonia_so...
## [7] --------------------------...LTRGT-QAYATAGGRLAGAAAG--- PH4H_Caulobacter_...
## [8] --------------------------...------------------------- PH4H_Pseudomonas_...
## [9] --------------------------...------------------------- PH4H_Rhizobium_loti
## Con --------------------------...??????????????IL??A???--- Consensus
```

Se ha creado la secuencia consenso de las 9 secuencias alineadas. Observad que no se muestra el alineamiento completo. Podemos utilizar el método `print()` con el argumento `show="complete"`, para mostrar las secuencias completas.

```
print(myFirstAlignment, show="complete")
```

```
##
## MsaAAMultipleAlignment with 9 rows and 456 columns
##     aln (1..54)                                            names
## [1] MAAVVLENGVLSRKLSDFGQETSYIEDNSNQNGAISLIFSLKEEVGALAKVLRL PH4H_Rattus_norve...
## [2] MAAVVLENGVLSRKLSDFGQETSYIEDNSNQNGAVSLIFSLKEEVGALAKVLRL PH4H_Mus_musculus
## [3] MSTAVLENPGLGRKLSDFGQETSYIEDNCNQNGAISLIFSLKEEVGALAKVLRL PH4H_Homo_sapiens
## [4] MSALVLESRALGRKLSDFGQETSYIEGNSDQN-AVSLIFSLKEEVGALARVLRL PH4H_Bos_taurus
## [5] ------------------------------------------------------ PH4H_Chromobacter...
## [6] ------------------------------------------------------ PH4H_Ralstonia_so...
## [7] ------------------------------------------------------ PH4H_Caulobacter_...
## [8] ------------------------------------------------------ PH4H_Pseudomonas_...
## [9] ------------------------------------------------------ PH4H_Rhizobium_loti
## Con ------------------------------------------------------ Consensus
##
##     aln (55..108)                                          names
## [1] FEENDINLTHIESRPSRLNKDEYEFFTYLDKRTKPVLGSIIKSLRNDIGATVHE PH4H_Rattus_norve...
## [2] FEENEINLTHIESRPSRLNKDEYEFFTYLDKRSKPVLGSIIKSLRNDIGATVHE PH4H_Mus_musculus
## [3] FEENDVNLTHIESRPSRLKKDEYEFFTHLDKRSLPALTNIIKILRHDIGATVHE PH4H_Homo_sapiens
## [4] FEENDINLTHIESRPSRLRKDEYEFFTNLDQRSVPALANIIKILRHDIGATVHE PH4H_Bos_taurus
## [5] ------------------------------------------------------ PH4H_Chromobacter...
## [6] ------------------------------------------------------ PH4H_Ralstonia_so...
## [7] ------------------------------------------------------ PH4H_Caulobacter_...
## [8] ------------------------------------------------------ PH4H_Pseudomonas_...
## [9] ------------------------------------------------------ PH4H_Rhizobium_loti
## Con ------------------------------------------------------ Consensus
##
##     aln (109..162)                                         names
## [1] LSRDKEKNTVPWFPRTIQELDRFANQILSYGAELDADHPGFKDPVYRARRKQFA PH4H_Rattus_norve...
## [2] LSRDKEKNTVPWFPRTIQELDRFANQILSYGAELDADHPGFKDPVYRARRKQFA PH4H_Mus_musculus
## [3] LSRDKKKDTVPWFPRTIQELDRFANQILSYGAELDADHPGFKDPVYRARRKQFA PH4H_Homo_sapiens
## [4] LSRDKKKDTVPWFPRTIQELDNFANQVLSYGAELDADHPGFKDPVYRARRKQFA PH4H_Bos_taurus
## [5] ------------------------MNDRADFVVPD-----ITTRKNVGLSHDAN PH4H_Chromobacter...
## [6] ------------------MAIATPTSAAPTPAPAGFTGTLTDKLREQFAEGLD PH4H_Ralstonia_so...
## [7] ------------------------MSG---------------DGLSNGPPPGAR PH4H_Caulobacter_...
## [8] -----------------------------------------MKTTQYVARQPD PH4H_Pseudomonas_...
## [9] ------------------------MSVAEYAR----------DCAAQGLRGDYS PH4H_Rhizobium_loti
## Con -------------------??????????Y????D???????D??????R?Q?? Consensus
##
##     aln (163..216)                                         names
## [1] DIAYNYRHGQPIPRVEYTEEEKQTWGTVFRTLKALYKTHACYEHNHIFPLLEKY PH4H_Rattus_norve...
## [2] DIAYNYRHGQPIPRVEYTEEERKTWGTVFRTLKALYKTHACYEHNHIFPLLEKY PH4H_Mus_musculus
## [3] DIAYNYRHGQPIPRVEYMEEEKKTWGTVFKTLKSLYKTHACYEYNHIFPLLEKY PH4H_Homo_sapiens
## [4] DIAYNYRHGQPIPRVEYTEEEKKTWGTVFRTLKSLYKTHACYEHNHIFPLLEKY PH4H_Bos_taurus
## [5] ------DFTLPQPLDRYSAEDHATWATLYQRQCKLLPGRACDEFMEGL----ER PH4H_Chromobacter...
## [6] GQTLRPDFTMEQPVHRYTAADHATWRTLYDRQEALLPGRACDEFLQGL----ST PH4H_Ralstonia_so...
## [7] -----PDWTIDQGWETYTQAEHDVWITLYERQTDMLHGRACDEFMRGL----DA PH4H_Caulobacter_...
## [8] ----------DNGFIHYPETEHQVWNTLITRQLKVIEGRACQEYLDGI----EQ PH4H_Pseudomonas_...
## [9] --VCRADFTVAQDYD-YSDEEQAVWRTLCDRQTKLTRKLAHHSYLDGV----EK PH4H_Rhizobium_loti
## Con ?????????P?P???YTEEE??TW?TL??RQ??L????AC?E???G?----?? Consensus
##
##     aln (217..270)                                         names
## [1] CGFREDNIPQLEDVSQFLQTCTGFRLRPVAGLLSSRDFLGGLAFRVFHCTQYIR PH4H_Rattus_norve...
## [2] CGFREDNIPQLEDVSQFLQTCTGFRLRPVAGLLSSRDFLGGLAFRVFHCTQYIR PH4H_Mus_musculus
## [3] CGFHEDNIPQLEDVSQFLQTCTGFRLRPVAGLLSSRDFLGGLAFRVFHCTQYIR PH4H_Homo_sapiens
## [4] CGFREDNIPQLEEVSQFLQSCTGFRLRPVAGLLSSRDFLGGLAFRVFHCTQYIR PH4H_Bos_taurus
## [5] LEVDADRVPDFNKLNQKLMAATGWKIVAVPGLIPDDVFFEHLANRRFPVTWWLR PH4H_Chromobacter...
## [6] LGMSREGVPSFDRLNETLMRATGWQIVAVPGLVPDEVFFEHLANRRFPASWWMR PH4H_Ralstonia_so...
## [7] LDLHRSGIPDFARINEELKRLTGWTVVAVPGLVPDDVFFDHLANRRFPAGQFIR PH4H_Caulobacter_...
## [8] LGLPHERIPQLDEINRVLQATTGWRVARVPALIPFQTFFELLASQQFPVATFIR PH4H_Pseudomonas_...
## [9] LGL-LDRIPDFEDVSTKLRKLTGWEIIAVPGLIPAAPFFDHLANRRFPVTNWLR PH4H_Rhizobium_loti
## Con LG???D?IPQLE?VSQ?LQ??TGWR???VPGL?P???FF??LA?R?FP?TQ?IR Consensus
##
##     aln (271..324)                                         names
## [1] HGSKPMYTPEPDICHELLGHVPLFSDRSFAQFSQEIG-LASLGAPDEYIEKLAT PH4H_Rattus_norve...
## [2] HGSKPMYTPEPDICHELLGHVPLFSDRSFAQFSQEIG-LASLGAPDEYIEKLAT PH4H_Mus_musculus
## [3] HGSKPMYTPEPDICHELLGHVPLFSDRSFAQFSQEIG-LASLGAPDEYIEKLAT PH4H_Homo_sapiens
## [4] HGSKPMYTPEPDICHELLGHVPLFSDRSFAQFSQEIG-LASLGAPDEYIEKLAT PH4H_Bos_taurus
## [5] EPHQLDYLQEPDVFHDLFGHVPLLINPVFADYLEAYGKGGVKAKALGALPMLAR PH4H_Chromobacter...
## [6] RPDQLDYLQEPDGFHDIFGHVPLLINPVFADYMQAYGQGGLKAARLGALDMLAR PH4H_Ralstonia_so...
## [7] KPHELDYLQEPDIFHDVFGHVPMLTDPVFADYMQAYGEGGRRALGLGRLANLAR PH4H_Caulobacter_...
## [8] TPEELDYLQEPDIFHEIFGHCPLLTNPWFAEFTHTYGKLGLKASKE-ERVFLAR PH4H_Pseudomonas_...
## [9] TRQELDYIVEPDMFHDFFGHVPVLSQPVFADFMQMYGKKAGDIIALGGDEMITR PH4H_Rhizobium_loti
## Con ????LDY??EPDIFHELFGHVPLLSDP?FA?F?Q?YG?LA???A?????E?LAR Consensus
##
##     aln (325..378)                                         names
## [1] IYWFTVEFGLCKEG-DSIKAYGAGLLSSFGELQYCLSD-KPKLLPLELEKTACQ PH4H_Rattus_norve...
## [2] IYWFTVEFGLCKEG-DSIKAYGAGLLSSFGELQYCLSD-KPKLLPLELEKTACQ PH4H_Mus_musculus
## [3] IYWFTVEFGLCKQG-DSIKAYGAGLLSSFGELQYCLSE-KPKLLPLELEKTAIQ PH4H_Homo_sapiens
## [4] IYWFTVEFGLCKQG-DSIKAYGAGLLSSFGELQYCLSD-KPKLLPLELEKTAVQ PH4H_Bos_taurus
## [5] LYWYTVEFGLINTP-AGMRIYGAGILSSKSESIYCLDSASPNRVGFDLMRIMNT PH4H_Chromobacter...
## [6] LYWYTVEFGLIRTP-AGLRIYGAGIVSSKSESVYALDSASPNRIGFDVHRIMRT PH4H_Ralstonia_so...
## [7] LYWYTVEFGLMNTP-AGLRIYGAGIVSSRTESIFALDDPSPNRIGFDLERVMRT PH4H_Caulobacter_...
## [8] LYWMTIEFGLVETD-QGKRIYGGGILSSPKETVYSLSD-EPLHQAFNPLEAMRT PH4H_Pseudomonas_...
## [9] LYWYTAEYGLVQEAGQPLKAFGAGLMSSFTELQFAVEGKDAHHVPFDLETVMRT PH4H_Rhizobium_loti
## Con LYW?TVEFGL????-???KAYGAGLLSSF?ELQYCLSD-?P???PF?LE??M?T Consensus
##
##     aln (379..432)                                         names
## [1] EYSVTEFQPLYYVAESFSDAKEKVRTFAATIPRPFSVRYDPYTQRVEVLDNTQQ PH4H_Rattus_norve...
## [2] EYTVTEFQPLYYVAESFNDAKEKVRTFAATIPRPFSVRYDPYTQRVEVLDNTQQ PH4H_Mus_musculus
## [3] NYTVTEFQPLYYVAESFNDAKEKVRNFAATIPRPFSVRYDPYTQRIEVLDNTQQ PH4H_Homo_sapiens
## [4] EYTITEFQPLYYVAESFNDAKEKVRNFAATIPRPFSVHYDPYTQRIEVLDNTQQ PH4H_Bos_taurus
## [5] RYRIDTFQKTYFVIDSFKQLFDATA-PDFAPLYLQLADAQPWGAGDVAPDDLVL PH4H_Chromobacter...
## [6] RYRIDTFQKTYFVIDSFEQLFDATR-PDFTPLYEALGTLPTFGAGDVVDGDAVL PH4H_Ralstonia_so...
## [7] LYRIDDFQQVYFVIDSIQTLQEVTL-RDFGAIYERLASVSDIGVAEIVPGDAVL PH4H_Caulobacter_...
## [8] PYRIDILQPLYFVLPDLKRLFQLAQ-EDIMALVHEAMRLG-LHAPLFPPKQAA- PH4H_Pseudomonas_...
## [9] GYEIDKFQRAYFVLPSFDALRDAFQTADFEAIVARRKDQKALDPATV------- PH4H_Rhizobium_loti
## Con ?Y?ID?FQPLYFV??SF??L?E??R??D?T??????????P??????V?D???? Consensus
##
##     aln (433..456)           names
## [1] LKILADSINSEVGILCNALQKIKS PH4H_Rattus_norve...
## [2] LKILADSINSEVGILCHALQKIKS PH4H_Mus_musculus
## [3] LKILADSINSEIGILCSALQKIK- PH4H_Homo_sapiens
## [4] LKILADSISSEVEILCSALQKLK- PH4H_Bos_taurus
## [5] NAGDRQGWADTEDV---------- PH4H_Chromobacter...
## [6] NAGTREGWADTADI---------- PH4H_Ralstonia_so...
## [7] TRGT-QAYATAGGRLAGAAAG--- PH4H_Caulobacter_...
## [8] ------------------------ PH4H_Pseudomonas_...
## [9] ------------------------ PH4H_Rhizobium_loti
## Con ????????????IL??A???---- Consensus
```

`msa()` devuelve un objeto de la clase `MsaAAMultipleAlignment`.

```
class(myFirstAlignment)
```

```
## [1] "MsaAAMultipleAlignment"
## attr(,"package")
## [1] "msa"
```

Parámetros de la función `msa()`

El primer argumento de `msa()` es el objeto de la clase `XStringSet` que contiene las secuencias a alinear.

Como ya se ha mencionado anteriormente hay tres algoritmos implementados en esta función, que indicamos en el segundo argumento, `method`. El valor de este argumento puede ser uno de entre tres strings: `"ClustalW"`, `"ClustalOmega"` o `"Muscle"`. Alternativamente podríamos utilizar las funciones `msaClustalW()`, `msaClustalOmega()` o `msaMuscle()`, respectivamente.

Todas estas funciones tienen además otros argumentos que permiten controlar las características del alineamiento y que se detallan a continuación.

- `cluster` permite elegir el método de *clustering* para agrupar la secuencias y crear el árbol guía.
- `gapOpening` penalización por la creación de un nuevo hueco.
- `gapExtension` penalización por la extensión de un hueco que ya existe.
- `maxiters` número máximo de interacciones.
- `substitutionMatrix` matriz de puntuación de los matches y mismatches.
- `type`, tipo de secuencia. Puede ser: `"dna"`, `"rna"`, o `"protein"`. Este argumento es obligatorio salvo que las secuencias se incluyan como un objeto de las clases `AAStringSet`, `DNAStringSet`, o `RNAStringSet`, que llevan incorporado en su definición el tipo de secuencia.
- `order`, orden de las secuencias en el objeto de salida. Si se elige la opción `"aligned"`, las secuencias se ordenan según las ha ordenado el algoritmo de alineamiento. Si se elige la opción `"input"`, las secuencias se ordenan en el mismo orden que las secuencias originales. Con el algoritmo `"MUSCLE"` esta opción no está disponible
- `verbose` que tiene el valor `TRUE` para mostrar información detallada sobre el progreso del alineamiento, incluidos los valores de los parámetros de control utilizados.

Visualización de los alineamientos

El paquete `msa` tiene implementada la función `msaPrettyPrint()` que permite visualizar los alineamientos múltiples de una forma más amigable. Para que funcione debemos tener instalado un compilador LaTeX y el paquete `TEXshade` (Beitz 2000) de LaTeX. Podéis consultar la ayuda para aprender a utilizar esta función.

En este caso, vamos a utilizar el paquete `ggmsa` de Bioconductor que implementa una herramienta exploratoria de los alineamientos múltiples utilizando el paquete `ggplot2` y que no requiere el manejo de LaTeX. Los alineamientos múltiples pueden combinarse fácilmente con otros `ggplots` tales como árboles filogenéticos, mapas genómicos etc, además de permitir anotar las alineaciones de las secuencias.

Instalación

Instalamos y cargamos el paquete,

```
if(!("ggmsa" %in% installed.packages()))
  BiocManager::install("ggmsa", force=TRUE)
library("ggmsa")
```

Nota:

Este paquete no está disponible para versiones de Bioconductor inferiores a 3.14 que no se puede usar en versiones de R inferiores a 4.1. Si estáis trabajando con versiones inferiores de Bioconductor tenéis que actualizar `BiocManager` con la instrucción,

```
BiocManager::install(version = "3.14")
```

También puede daros problemas el paquete `rlang`. Si es así, podéis desintalarlo y volver a instalarlo.

Uso básico de `ggmsa`

Lo primero que vamos a hacer es utilizar la función `writeXStringSet()` del paquete `Biostrings` para crear un archivo FASTA con el resultado del alineamiento. Debemos usar también la función `unmasked()` de este mismo paquete, que traduce el objeto a uno de tipo `XString`.

```
writeXStringSet(unmasked(myFirstAlignment), file="myAlign.Clustal.fasta")
```

Necesitamos un `string` con el nombre (ruta completa) del fichero FASTA donde tenemos el resultado alineamiento,

```
myAlign.Clustal <- "myAlign.Clustal.fasta"
```

El código más sencillo para usar `ggmsa`,

```
ggmsa(myAlign.Clustal, start=300, end=350,
      color = "Taylor_AA", font = "DroidSansMono",
      char_width = 0.5,
      seq_name = TRUE)
```

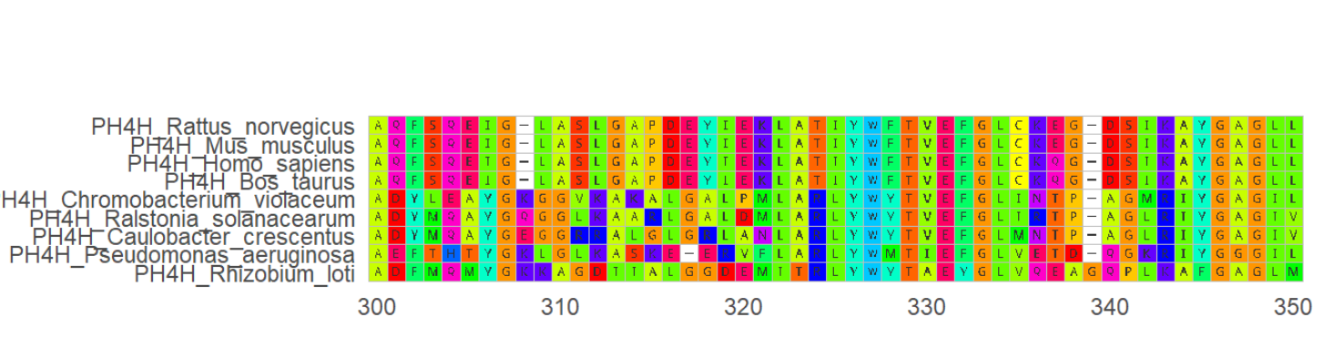

Estamos representando las secuencias entre el residuo 300 y 350 de nuestro alineamiento. Con el argumento `seq_name=TRUE` añadimos el nombre de la secuencia.

`ggmsa` tiene patrones de colores predefinidos que se pueden usar en el argumento `color`. Estos patrones son diferentes dependiendo de que se trate de nucleótidos o aminoácidos, según el esquema siguiente,

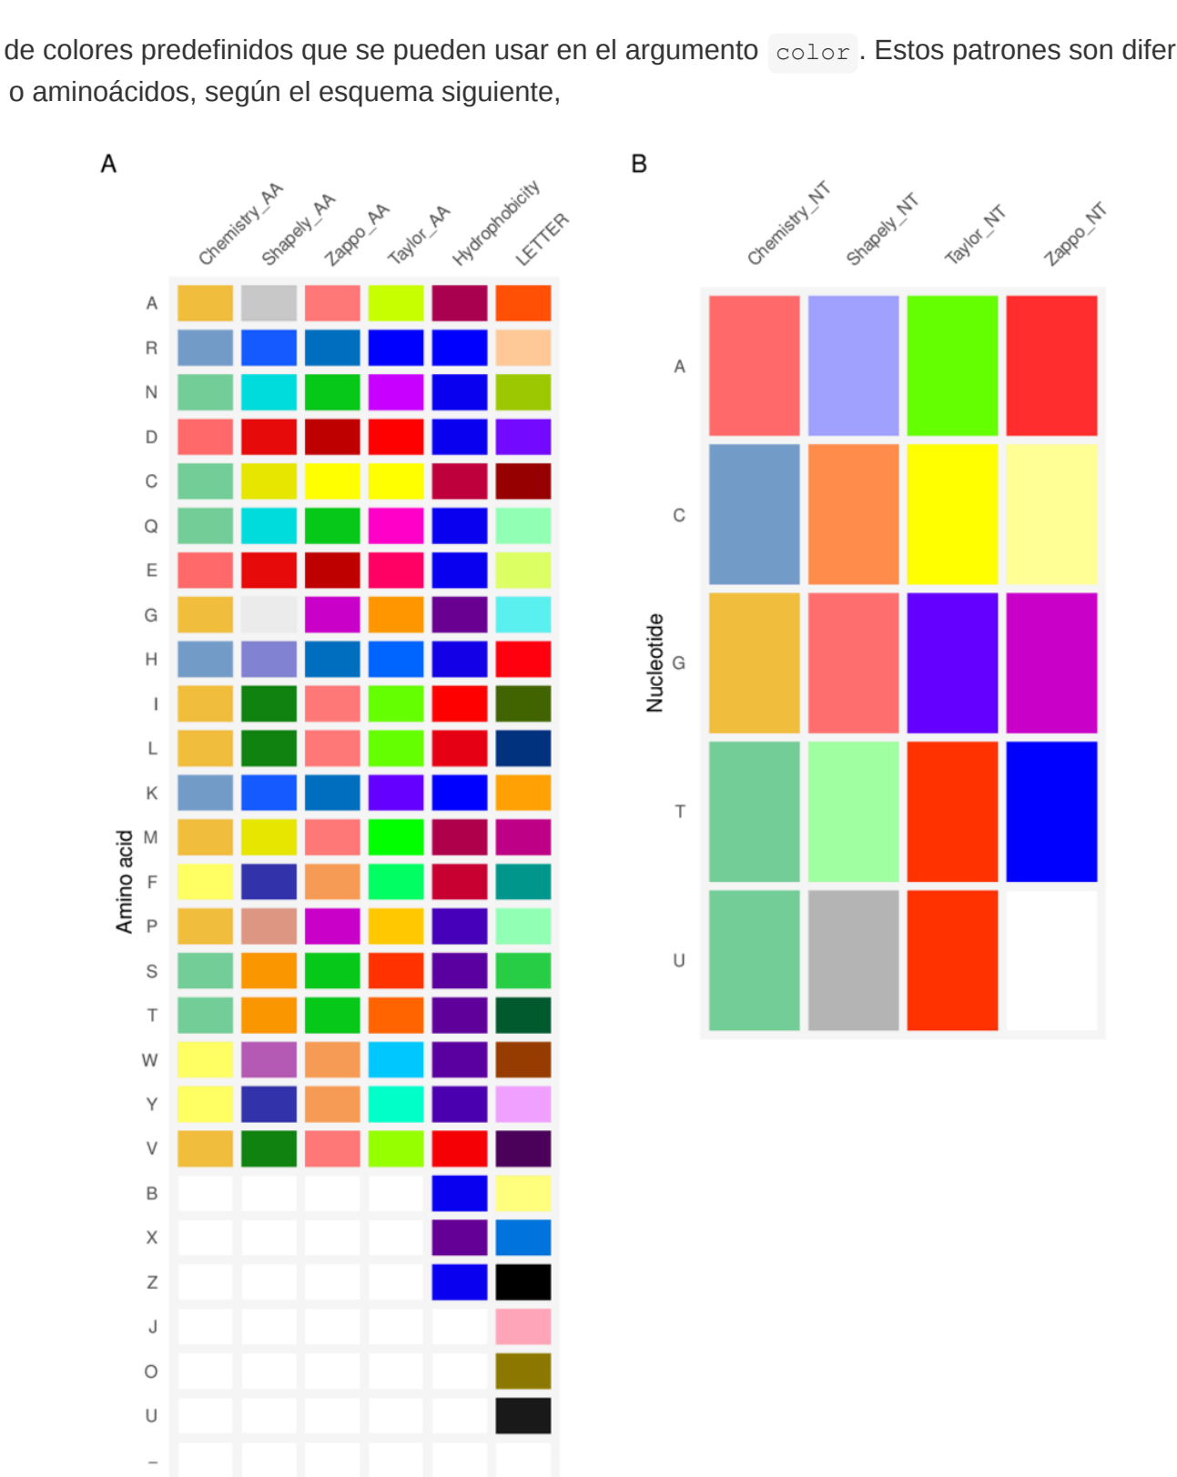

Se pueden consultar los esquemas aplicables a las diferentes secuencias con la función `available_colors()`,

```
available_colors()
```

También se puede elegir la fuente de la letra. Para consltar las fuentes disponibles se puede utilizar `available_fonts()`,

```
available_fonts()
```

Anotaciones

`ggmsa` soporta anotaciones para el alineamiento múltiple. De manera similar a como se trabaja con `ggplot2`, hay implementadas anotaciones utilizando `geom` que se pueden añadir con el símbolo `+`: `ggmsa() + geom_*()`.

Las anotaciones que es posible añadir a la representación del alineamiento se resumen en la siguiente tabla,

Sintaxis	Descripción
geom_seqlogo()	Añadir el logo de secuencia
geom_GC()	Contenido de GC con un plot de burbujas
geom_seed()	Señalar las regiones 'semilla' en secuencias de miRNA
geom_msaBar()	Diagrama de barras de la secuencia consenso
geom_helix()	Representa la estructura secundaria el RNA como diagramas de arco

Por ejemplo, para visualizar el alineamiento múltiple con el logo de secuencia y un diagrama de barras de la secuencia consenso,

```
ggmsa(myAlign.Clustal, 221, 280, seq_name = TRUE, char_width = 0.5) +
  geom_seqlogo(color = "Chemistry_AA") +
  geom_msaBar()
```

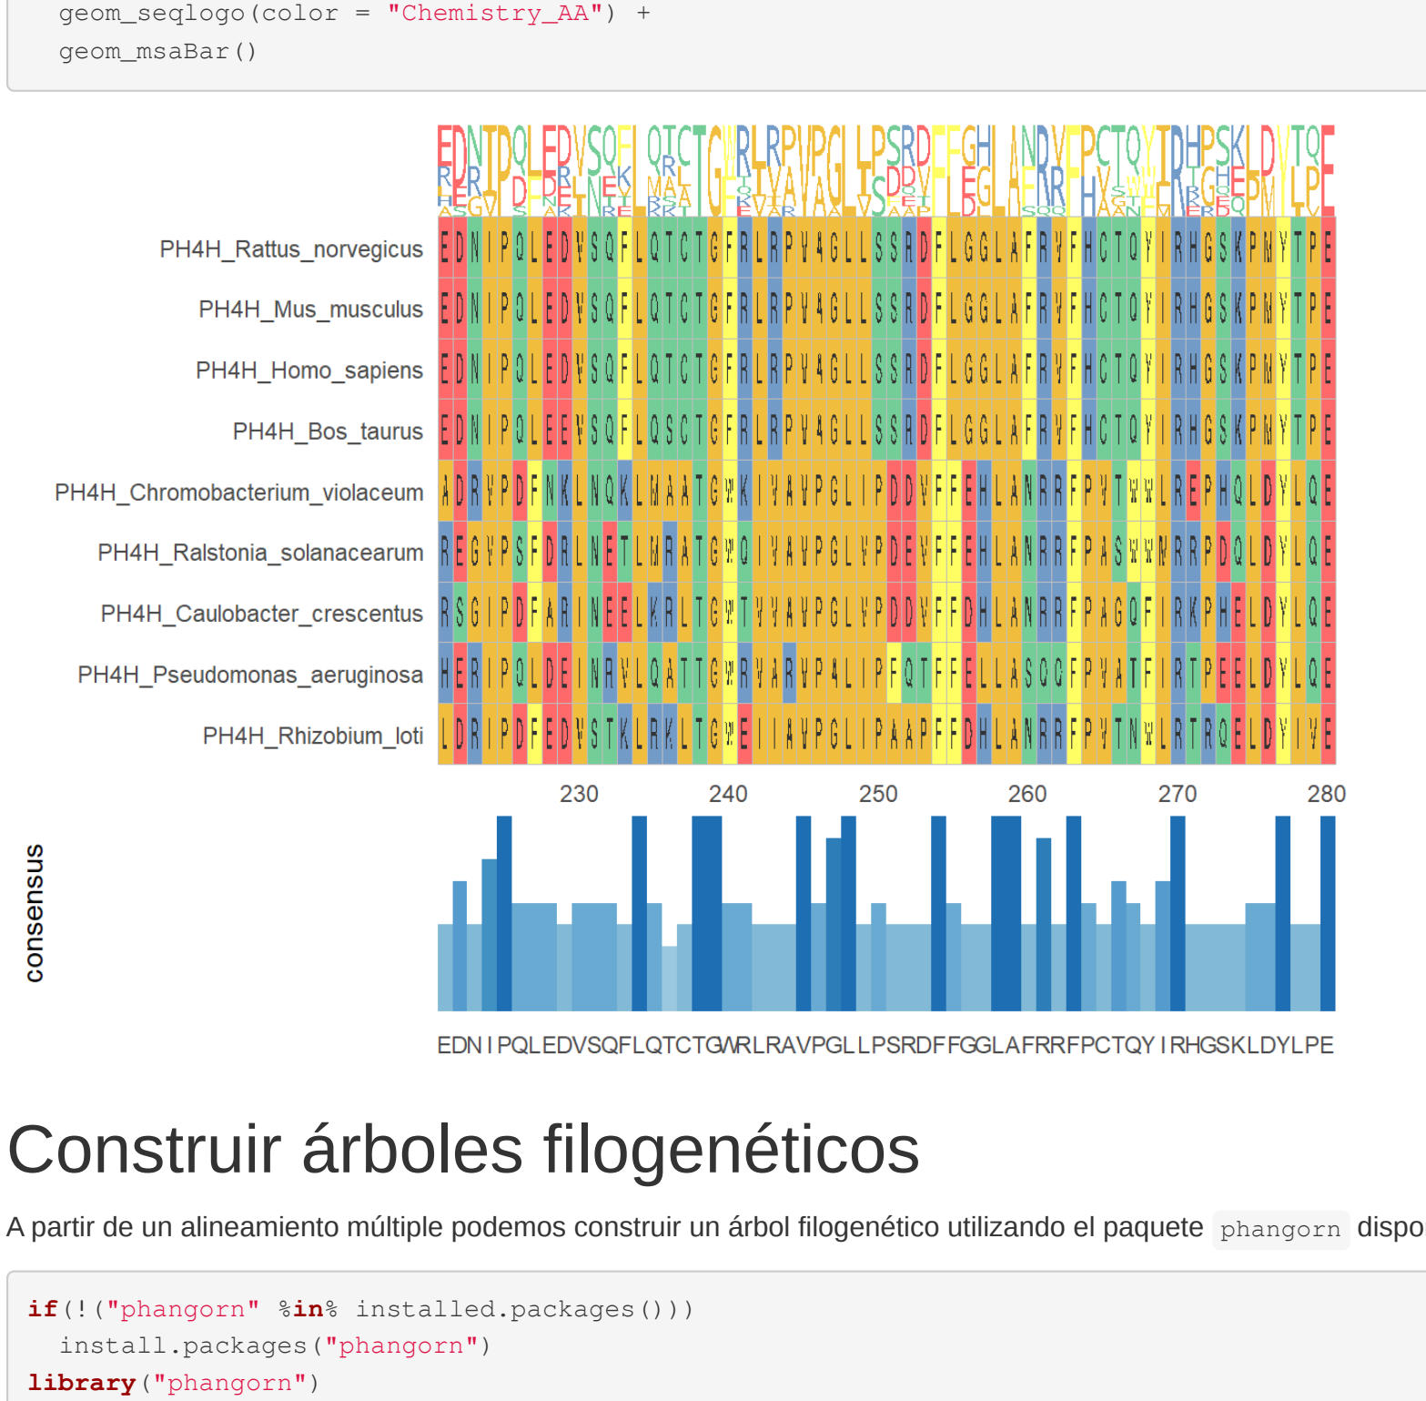

Construir árboles filogenéticos

A partir de un alineamiento múltiple podemos construir un árbol filogenético utilizando el paquete `phangorn` disponible en CRAN.

```
if(!("phangorn" %in% installed.packages()))
  install.packages("phangorn")
library("phangorn")
```

Seguimos los siguientes pasos:

1. Convertir el alineaminto en un objeto de tipo `phyDat`. Usamos el argumento `type = "AA"` para indicar que estamos manejando secuencias de aminoácidos. Usaríamos `type = "DNA"` para nucleótidos.

```
myFirstAlignment <- msa(mySequences)
```

```
## use default substitution matrix
```

```
aln <- as.phyDat(myFirstAlignment, type = "AA")
```

2. Los árboles se construyen a partir de matrices de distancias, por lo que lo primero que tendremos que hacer es calcular esas distancias a partir del alineamiento con la función `dist.ml()`. Podríamos utilizar otras funciones de distancia para hacer este cálculo.

```
(dist_mat <- dist.ml(aln))
```

```
##                                PH4H_Rattus_norvegicus PH4H_Mus_musculus
## PH4H_Mus_musculus                          0.01782625
## PH4H_Homo_sapiens                          0.08077210        0.07836643
## PH4H_Bos_taurus                            0.09310910        0.08580044
## PH4H_Chromobacterium_violaceum             1.47622047        1.47622047
## PH4H_Ralstonia_solanacearum                1.57238711        1.57238711
## PH4H_Caulobacter_crescentus                1.48023739        1.48023739
## PH4H_Pseudomonas_aeruginosa                1.36471061        1.38096422
## PH4H_Rhizobium_loti                        1.31992538        1.31992538
##                                PH4H_Homo_sapiens PH4H_Bos_taurus
## PH4H_Mus_musculus
## PH4H_Homo_sapiens
## PH4H_Bos_taurus                       0.07614220
## PH4H_Chromobacterium_violaceum        1.47622047      1.46032052
## PH4H_Ralstonia_solanacearum           1.60665593      1.57238711
## PH4H_Caulobacter_crescentus           1.49664540      1.48023739
## PH4H_Pseudomonas_aeruginosa           1.38096422      1.36471061
## PH4H_Rhizobium_loti                   1.33479266      1.33479266
##                                PH4H_Chromobacterium_violaceum
## PH4H_Mus_musculus
## PH4H_Homo_sapiens
## PH4H_Bos_taurus
## PH4H_Chromobacterium_violaceum
## PH4H_Ralstonia_solanacearum                        0.37990357
## PH4H_Caulobacter_crescentus                        0.59853409
## PH4H_Pseudomonas_aeruginosa                        0.90605797
## PH4H_Rhizobium_loti                                0.81339683
##                                PH4H_Ralstonia_solanacearum
## PH4H_Mus_musculus
## PH4H_Homo_sapiens
## PH4H_Bos_taurus
## PH4H_Chromobacterium_violaceum
## PH4H_Ralstonia_solanacearum
## PH4H_Caulobacter_crescentus                     0.52646616
## PH4H_Pseudomonas_aeruginosa                     0.87679487
## PH4H_Rhizobium_loti                             0.92116366
##                                PH4H_Caulobacter_crescentus
## PH4H_Mus_musculus
## PH4H_Homo_sapiens
## PH4H_Bos_taurus
## PH4H_Chromobacterium_violaceum
## PH4H_Ralstonia_solanacearum
## PH4H_Caulobacter_crescentus
## PH4H_Pseudomonas_aeruginosa                     0.90605797
## PH4H_Rhizobium_loti                             0.84212975
##                                PH4H_Pseudomonas_aeruginosa
## PH4H_Mus_musculus
## PH4H_Homo_sapiens
## PH4H_Bos_taurus
## PH4H_Chromobacterium_violaceum
## PH4H_Ralstonia_solanacearum
## PH4H_Caulobacter_crescentus
## PH4H_Pseudomonas_aeruginosa
## PH4H_Rhizobium_loti                             1.01041280
```

3. Hay dos tipos de árboles que podemos construir: *UPGMA* y *Neighbor Joining Tree* (NJ). El primero se basa en un *clustering* jerárquico aglomerativo y el segundo en un método de *clustering* iterativo basado en el criterio de mínima distancia. No entraremos en detalle sobre los algoritmos. Usamos la función `plot()` para representarlos.

```
upgma_tree <- upgma(dist_mat)
plot(upgma_tree, main="UPGMA")
```

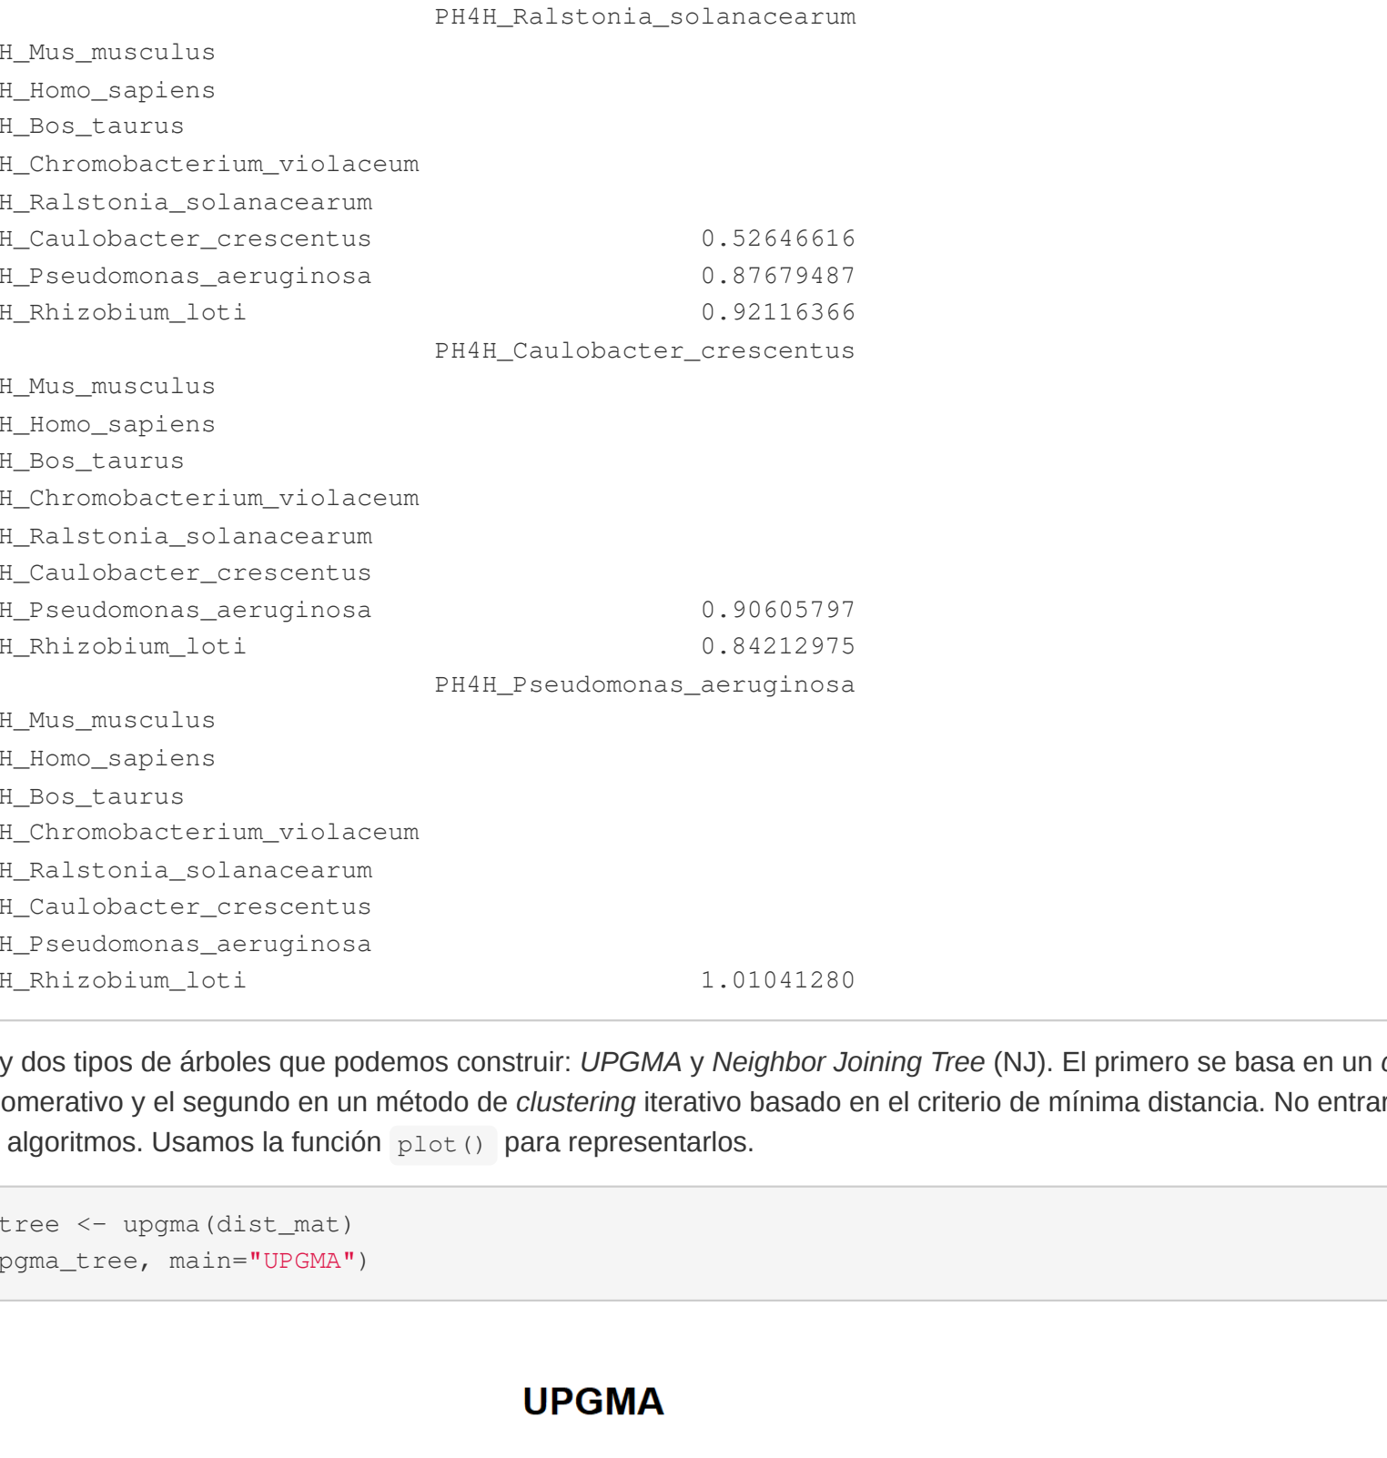
UPGMA
PH4H Ralstonia solanacearum
PH4H Chromobacterium violaceum
PH4H Caulobacter crescentus
PH4H Rhizobium loti
PH4H Pseudomonas aeruginosa
PH4H Bos taurus
PH4H Homo sapiens
PH4H Mus musculus
PH4H Rattus norvegicus

```
nj_tree <- NJ(dist_mat)
plot(nj_tree, main="NJ")
```

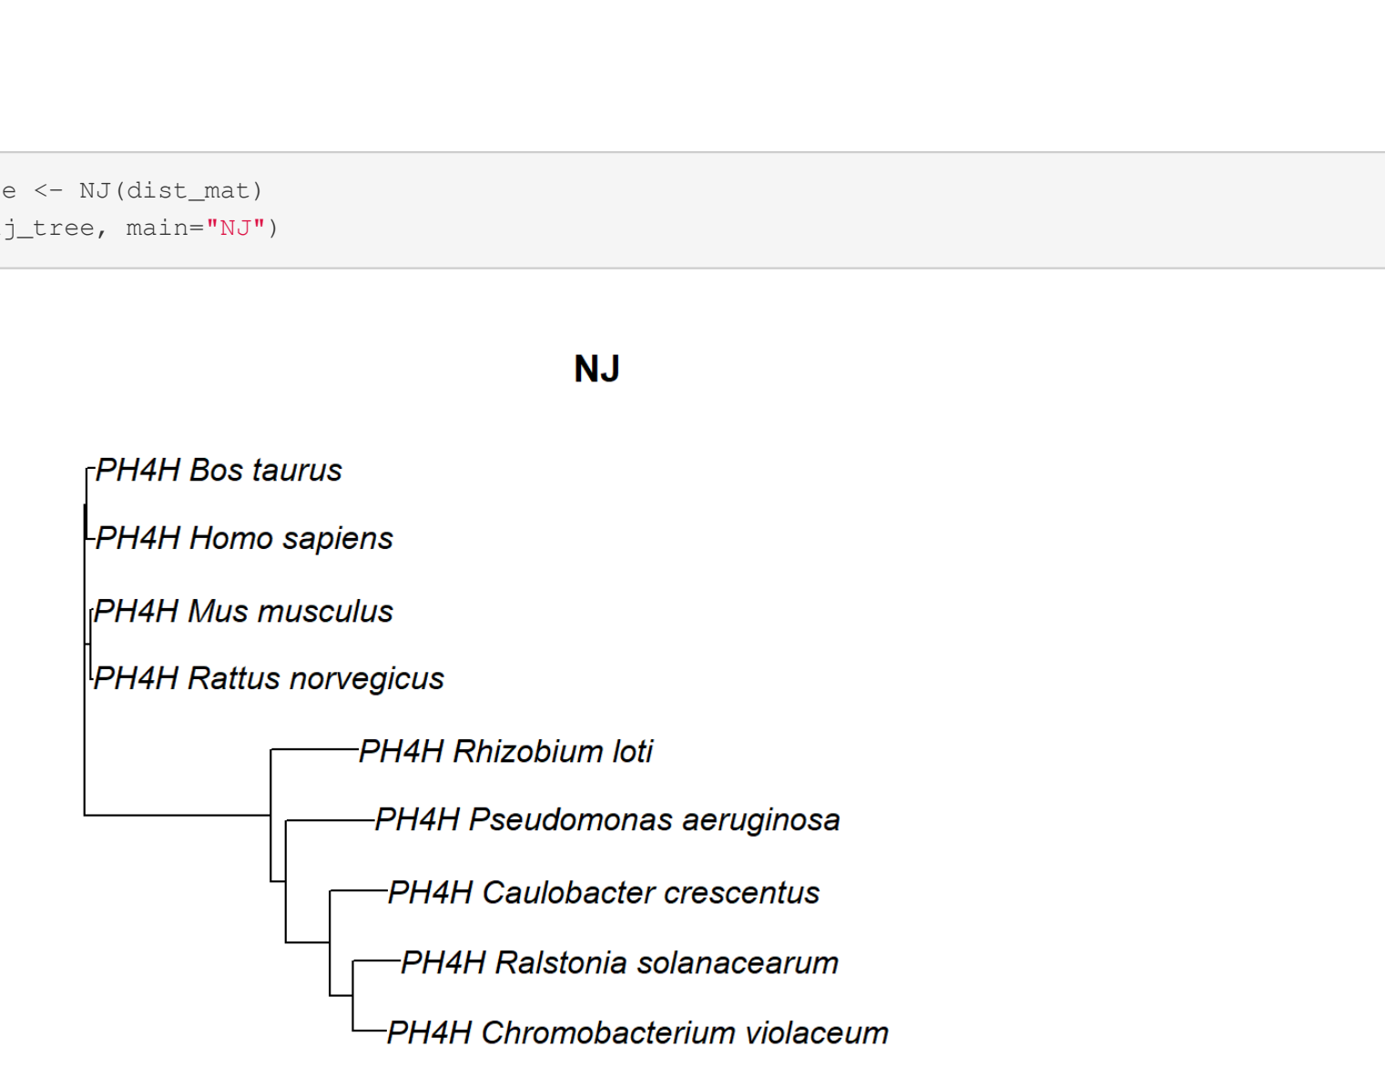
NJ
PH4H Bos taurus
PH4H Homo sapiens
PH4H Mus musculus
PH4H Rattus norvegicus
PH4H Rhizobium loti
PH4H Pseudomonas aeruginosa
PH4H Caulobacter crescentus
PH4H Ralstonia solanacearum
PH4H Chromobacterium violaceum

Referencias

Beitz, Eric. 2000. "TeXshade: Shading and Labeling of Multiple Sequence Alignments Using LaTeX2e." *Bioinformatics* 16 (2): 135–39.

Edgar, Robert C. 2004a. "MUSCLE: A Multiple Sequence Alignment Method with Reduced Time and Space Complexity." *BMC Bioinformatics* 5 (1): 1–19.

———. 2004b. "MUSCLE: Multiple Sequence Alignment with High Accuracy and High Throughput." *Nucleic Acids Research* 32 (5): 1792–97.

Sievers, Fabian, Andreas Wilm, David Dineen, Toby J Gibson, Kevin Karplus, Weizhong Li, Rodrigo Lopez, et al. 2011. "Fast, Scalable Generation of High-Quality Protein Multiple Sequence Alignments Using Clustal Omega." *Molecular Systems Biology* 7 (1): 539.

Thompson, Julie D, Desmond G Higgins, and Toby J Gibson. 1994. "CLUSTAL W: Improving the Sensitivity of Progressive Multiple Sequence Alignment Through Sequence Weighting, Position-Specific Gap Penalties and Weight Matrix Choice." *Nucleic Acids Research* 22 (22): 4673–80.