


Transcriptómica: Análisis de datos de microarrays



- Los **microarrays** son una herramienta ampliamente utilizada para estudiar la expresión génica a gran escala.
- La **expresión de un gen** es el proceso mediante el que se transcribe el DNA en una serie de copias de mRNA.
- Los microarrays permiten cuantificar la **cantidad de moléculas de mRNA** para miles de genes simultáneamente.
- Se **asume** que la cantidad de mRNA es una estimación del **nivel de expresión** del gen, aunque esta relación puede no ser exacta.
- La señal obtenida en los microarrays de expresión es una **medida de fluorescencia** relacionada con la cantidad de mRNA hibridado.
- Esta relación puede estar influida por **factores técnicos** y no siempre es estrictamente proporcional.
- El punto de partida del análisis será una **matriz de intensidades** que se somete a:
 - Normalización, corrección de fondo, sumarización (pre-procesamiento)
 - Identificación de genes relevantes (análisis de expresión diferencial)
 - Descubrimiento de patrones comunes entre genes o muestras,...





Algunos aspectos sobre la tecnología



¿Qué es un microarray y como funciona?

- Un microarray es un dispositivo que permite medir simultáneamente la expresión de miles de genes.
- Contiene sondas de DNA (probes) fijadas sobre una superficie sólida (cristal, plástico u otro soporte).
- Cada sonda representa un gen o fragmento específico de DNA.
- Al aplicar una muestra biológica (mRNA marcado o cDNA), se produce hibridación entre las sondas y las secuencias complementarias presentes en la muestra.
- El nivel de hibridación se detecta mediante fluorescencia, que se mide con un escáner de alta sensibilidad.
- La intensidad fluorescente es proporcional (con matices) a la cantidad de mRNA hibridado, y por tanto a la expresión del gen correspondiente.

- Existen distintos tipos de microarrays según la molécula analizada:
 - Microarrays de expresión génica (los más comunes): cuantifican mRNA.
 - Arrays de DNA: detección de variaciones genéticas (CGH, SNPs).
 - Arrays de proteínas: detección de niveles o interacciones proteicas.
 - Arrays de tejidos: permiten estudiar múltiples muestras histológicas.de proteínas
- Desde el punto de vista tecnológico, distinguimos principalmente:
 - Arrays de cDNA (dos canales): usan DNA complementario fijado, y comparan dos muestras marcadas con fluoróforos distintos
 - Arrays de oligonucleótidos (un canal): usan sondas sintéticas de oligos cortos, con una única muestra marcada por array
- En ambos casos:
 - El principio es la hibridación específica entre sonda y diana.
 - Se diferencian por el tipo de sonda, el sistema de marcado y el análisis de imagen.






En los **arrays de oligonucleótidos (un canal)**:

- En este tipo de microarrays, las sondas son oligonucleótidos sintéticos (25–60 nucleótidos), fijados directamente sobre el soporte mediante síntesis in situ.
- Cada gen se representa mediante un conjunto de sondas específicas llamado probe-set.
- Estas sondas tienen secuencias diferentes pero complementarias a regiones distintas del mismo gen.
- El diseño incluye disposición aleatoria de las sondas sobre la superficie del chip para evitar efectos de posición.
- El objetivo es obtener una medida robusta y precisa del nivel de expresión de cada gen.
- Affymetrix ha sido una de las empresas pioneras y referentes en este tipo de tecnología.



Hibridación y detección de señal en microarrays


- Cada microarray contiene miles de microceldas, cada una con copias de una sonda específica.
- Las moléculas diana (mRNA o cDNA marcado) hibridan con las sondas complementarias.
- Tras el lavado, un escáner láser excita los fluoróforos y detecta la señal fluorescente emitida.
- La intensidad de fluorescencia en cada microcelda es proporcional (aunque no de forma estricta) a la cantidad de hibridación.
- El resultado es una imagen digital de alta resolución, donde:
 - Cada punto brillante representa una sonda.
 - Su brillo refleja el nivel de expresión del gen correspondiente.
- Esta imagen será posteriormente cuantificada para convertirla en datos numéricos.





De la imagen al dato: cómo se estima la expresión génica

- La imagen fluorescente generada por el escáner se convierte en valores numéricos mediante análisis de imagen.
- Cada píxel representa la señal en una microcelda → se cuantifica y se obtiene una matriz de intensidades.
- Para cada gen, las sondas asociadas (probe-set) deben combinarse para estimar un único valor de expresión.
- En microarrays de Affymetrix, cada sonda se presenta en parejas:
 - Perfect Match (PM): secuencia complementaria exacta al gen objetivo.
 - MisMatch (MM): igual que la PM, pero con un solo nucleótido cambiado (en el centro).
- El objetivo del MM es detectar hibridaciones no específicas (ruido de fondo).
- El valor de expresión final se obtiene al combinar la señal de PM y MM, ajustando por background.
- El resultado de este proceso es una matriz de expresión, donde:
 - Las filas corresponden a genes o entidades génicas
 - Las columnas son muestras (una por microarray)
 - Cada celda contiene una medida de nivel de expresión



- Perfect Match (PM)
- MisMatch (MM) – control hibridación

PM: CGATCAATTGCACTATGTCATTCT
MM: CGATCAATTGCAATATGTCATTCT



Datos de microarrays



Niveles de información en un experimento de microarrays

En un análisis típico de microarrays (como los de Affymetrix), se generan tres niveles de datos:

1. Nivel de **imagen**



- Representa la señal fluorescente capturada por el escáner.
- Se guarda en archivos tipo .DAT, que contienen la imagen digital completa del microarray.

2. Nivel de **sonda** (raw data)


- Se extraen valores de intensidad de cada sonda individual (pixel o grupo de píxeles).
- Estos datos se almacenan en archivos .CEL.
- La correspondencia entre sondas y genes se define en archivos .CDF (*Chip Definition Files*), que indican qué sondas forman cada probe-set.


3. Nivel de **expresión génica** (preprocesado)

- Resultado del procesamiento y combinación de las señales crudas.
- Se organiza como una matriz de expresión:
 - Filas = genes
 - Columnas = muestras
 - Celdas = nivel de expresión estimado para cada gen en cada muestra.



**PM y MM para
cada probe en
cada microarray**






Tras el preprocesamiento, los niveles de expresión suelen transformarse con **logaritmo en base 2**. ¿Por qué?


1. Distribución sesgada: la mayoría de los genes tienen baja expresión → distribución muy asimétrica. El $\log_2$ reduce esa asimetría.
2. Comparabilidad: permite comparar genes sobreexpresados e infraexpresados de forma simétrica.
3. Interpretación del cambio:
 - En escala original: fold-change = cociente entre condiciones.
 - En escala $\log_2$: fold-change = diferencia.
 - $\log_2(2) = +1$ → duplicación de expresión.
 - $\log_2(0.5) = -1$ → reducción a la mitad.
 - Un fold-change en $\log_2$ de:
 - > 0 = sobreexpresión
 - < 0 = infraexpresión=
 - 0 = sin cambio

Fuentes de datos públicas

- Podemos acceder a una gran cantidad de datos de microarrays en la base de datos GEO (Gene Expression Omnibus) de NCBI (<http://www.ncbi.nlm.nih.gov/geo/>).
- Otra fuente interesante es ArrayExpress (EBI) (<http://www.ebi.ac.uk/arrayexpress>).



Accession	Title	Technology	Organism(s)	Data rows	Samples	Series	Contact	Release date
GPL16791	Illumina HiSeq 2500 (Homo sapiens)	high-throughput sequencing	Homo sapiens	270627	9402	GEO		Mar 14, 2013
GPL18573	Illumina NextSeq 500 (Homo sapiens)	high-throughput sequencing	Homo sapiens	259191	7918	GEO		Apr 15, 2014
GPL17021	Illumina HiSeq 2500 (Mus musculus)	high-throughput sequencing	Mus musculus	246168	8624	GEO		Apr 16, 2013
GPL24247	Illumina NovaSeq 6000 (Mus musculus)	high-throughput sequencing	Mus musculus	232461	3350	GEO		Nov 08, 2017
GPL19057	Illumina NextSeq 500 (Mus musculus)	high-throughput sequencing	Mus musculus					
GPL570	[HG-U133_Plus_2] Affymetrix Human Genome U133 Plus 2.0 Array	in situ oligonucleotide	Homo sapiens					
GPL13112	Illumina HiSeq 2000 (Mus musculus)	high-throughput sequencing	Mus musculus					
GPL11154	Illumina HiSeq 2000 (Homo sapiens)	high-throughput sequencing	Homo sapiens					
GPL20301	Illumina HiSeq 4000 (Homo sapiens)	high-throughput sequencing	Homo sapiens					
GPL13534	Illumina HumanMethylation450 BeadChip (HumanMethylation450_15017482)	oligonucleotide beads	Homo sapiens					
GPL24676	Illumina NovaSeq 6000 (Homo sapiens)	high-throughput sequencing	Homo sapiens					
GPL10558	Illumina HumanHT-12 V4.0 expression beadchip	oligonucleotide beads	Homo sapiens					
GPL21103	Illumina HiSeq 4000 (Mus musculus)	high-throughput sequencing	Mus musculus					
GPL1261	[Mouse430_2] Affymetrix Mouse Genome 430 2.0 Array	in situ oligonucleotide	Mus musculus					
GPL96	[HG-U133A] Affymetrix Human Genome U133A Array	high-throughput sequencing	Homo sapiens					
GPL21626	NextSeq 550 (Mus musculus)	high-throughput sequencing	Mus musculus					
GPL21145	Infinium MethylationEPIC	oligonucleotide beads	Homo sapiens					
GPL6244	[HuGene-1.0-st] Affymetrix Human Gene 1.0 ST Array (transcript (gene) version)	in situ oligonucleotide	Homo sapiens					
GPL6246	[MoGene-1.0-st] Affymetrix Mouse Gene 1.0 ST Array (transcript (gene) version)	in situ oligonucleotide	Mus musculus					
GPL21263	3D-Genome Human mRNA V21_1.0.0	spotted oligonucleotide	Homo sapiens					



EMBL-EBI Services Research Training About us

EMBL-EBI Hinxton

Search

Examples: E-MEXP-31, cancer, p53, Geuvadis

advanced search

Contact Us Login

ArrayExpress – functional genomics data

ArrayExpress Archive of Functional Genomics Data stores data from high-throughput functional genomics experiments, and provides these data for reuse to the research community.

Data Content

Updated on 20 April 2022 at 02:02

- 75500 experiments
- 2594218 assays
- 61.91 TB of archived data

[Browse ArrayExpress](#)

Latest News

26 February 2022 - **ArrayExpress collection now released in BioStudies**

The transition phase has begun! The **ArrayExpress collection** is now live in BioStudies. Head over to BioStudies and explore the **new look of the archive**, **study pages**, **search filters** and **download functionality**.

Here is an example: Current: **E-MTAB-7871** New: **E-MTAB-7871**

Note that not all datasets have been migrated from ArrayExpress to BioStudies yet, so you may not find a particular experiment and search results will differ.

A quick summary of the changes to expect:

Ambos repositorios permiten descargar:

- Archivos .CEL, .CDF, metadatos experimentales, y matrices de expresión

Pre-procesado: limpiar y preparar los datos



Antes de analizar los niveles de expresión, los datos deben corregirse para eliminar errores técnicos.

El proceso se conoce como preprocesado e incluye tres pasos clave:

1. Corrección de fondo

- Elimina la señal debida a hibridación inespecífica o ruido del escáner

2. Normalización

- Corrige sesgos sistemáticos entre arrays (por ejemplo, diferencias de escaneo o marcado)

3. Sumarización

- Combina los valores de las sondas (probe-set) para dar un único valor de expresión por gen

- Resultado: una matriz de expresión fiable y comparable entre muestras
- Métodos comunes: MAS5, RMA
- Es lo que se conoce como **análisis de bajo nivel**

Análisis de datos de microarrays

¿Qué analizamos en los microarrays?

Con la matriz de expresión ya limpia y normalizada, el análisis estadístico se centra en dos grandes objetivos:

1. Expresión diferencial

- Identificar genes cuya expresión cambia significativamente entre condiciones (por ejemplo, sanos vs enfermos).
- Se conocen como DEGs (*Differentially Expressed Genes*).

2. Análisis exploratorio

- Buscar patrones o estructuras ocultas en los datos.
- Permite descubrir grupos de genes coexpresados o muestras con perfiles similares.
- Puede ser:
 - No supervisado (sin etiquetas): clustering, PCA...
 - Supervisado (con etiquetas): clasificación, predicción...

Expresión diferencial

La forma más natural y sencilla de cuantificar la expresión diferencial podría ser utilizar fold-changes o log fold-changes: ratio de expresión entre una condición experimental y el control.

Estableciendo un determinado umbral consideraríamos diferencialmente expresados aquellos genes cuyo FC es superior/inferior a dicho umbral.

Comportamiento	Nivel Control (C)	Nivel Muestra (M)	Ratio (M/C)	Log Ratio $\log_2(M/C)$
Nivel base de expresión	50	50	1.0	0.0
Sin cambio	50	50	1.0	0.0
Activación doble	50	100	2.0	1.0
Inhibición doble	50	25	0.5	-1.0


Inconvenientes:

- ¿qué umbral establecemos? Es una decisión arbitraria.
- ¿están “significativamente” expresados?



¿Es significativo el cambio?

- Para cada gen, se plantea un contraste de hipótesis:
H₀: no hay diferencia de expresión entre grupos
H₁: sí hay diferencia de expresión
- Métodos paramétricos gen a gen:
 - Dos grupos: contraste t-Student para muestras dependientes / independientes
 - Múltiples grupos: ANOVA
 - Relación con variables cuantitativas: correlación y regresión
- Métodos no paramétricos son más raros puesto que son mucho más conservadores



Limitaciones de los contrastes clásicos gen a gen:

1. Valores extremos afectan mucho a los estadísticos test.
 2. Varianzas muy pequeñas → resultados inestables.
 3. Cada contraste usa pocos datos por gen (n pequeño).
 4. Distribuciones no normales → los supuestos del test pueden no cumplirse.
- Consecuencia: riesgo de falsos positivos o falsos negativos.
 - Solución: usar métodos que moderen o regularicen los estimadores, y compartan información entre genes.



Métodos mejorados para expresión diferencial

- SAM (*Significance Analysis of Microarrays*): Añade un pequeño valor a la varianza para evitar divisiones por casi cero
- Moderated t (limma, Empirical Bayes): Estima una varianza "moderada" combinando información entre genes → más estable



Contrastes gen a gen. En miles de genes: un grave problema de **comparaciones múltiples**.

- Si $p\text{-valor} < 0.01$ para un gen: hay un 1% de obtener un falso positivo
- Si contratamos 10000 genes: tendremos ~100 falsos positivos!
- Necesitamos hacer ajustes de los p-valores muy fuertes para controlar el número de falsos positivos.




Volcano plot

Representación de genes según su expresión diferencial y significación estadística

- Punto = gen
- X = cuánta expresión diferencial $\log_2(FC)$
- Y = significatividad estadística $-\log_{10}(p - \text{valor})$

Volcano plot: 60 min vs. 0 min





Análisis exploratorio



- En microarrays, cada muestra tiene miles de dimensiones (genes).
- El análisis exploratorio ayuda a:
 - Detectar agrupaciones de genes o subgrupos de muestras.
 - Reducir el ruido y entender la estructura de los datos.
- Dos enfoques principales:
 - Clustering (agrupamiento)
 - Análisis de componentes principales (PCA)


Análisis exploratorio: *clustering*



Clustering: agrupar elementos según su similitud (distancia, correlación...).

Aplicaciones:

- Agrupar genes con patrones similares → posible co-regulación.
- Agrupar muestras → subtipos, respuestas al tratamiento...
- Biclustering → grupa simultáneamente genes y condiciones





- El primer paso será calcular una medida del parecido (**similaridad**): distancia, correlación, etc
- **Linkage**: distancia entre dos clusters
 - Single: dada por los elementos más cercanos
 - Complete: dada por los más lejanos
 - Centroid: dada por el centroide del cluster

Single linkage clustering



Complete-linkage clustering




Centroid linkage




- Algoritmo de agrupación

Métodos **Divisorios**



Algoritmo de las K-medias

Métodos **Jerárquicos**



Aglomerativo



Biclustering

	A	B	C	D	E	F	G	H
Gen 1	Red	Green	White	Red	Green	Green	Red	Red
Gen 2	White	White	White	White	White	White	White	White
Gen 3	White	White	White	White	White	White	White	White
Gen 4	Red	Green	White	Red	Green	Green	Red	Red
Gen 5	White	White	White	White	White	White	White	White
Gen 6	White	Green	White	White	Green	Green	White	White
Gen 7	White	Green	White	White	Green	Green	White	White
Gen 8	White	White	White	White	White	White	White	White
Gen 9	Red	Green	White	Red	Green	Green	Red	Red

	A	B	C	D	E	F	G	H
Gen 1	Red	Green	White	Red	Green	Green	Red	Red
Gen 4	Red	Green	White	Red	Green	Green	Red	Red
Gen 9	Red	Green	White	Red	Green	Green	Red	Red

Cluster de genes
Genes con el mismo
"patrón de colores"

	B	E	F
Gen 1	Green	Green	Green
Gen 4	Green	Green	Green
Gen 6	Green	Green	Green
Gen 7	Green	Green	Green
Gen 9	Green	Green	Green

Bicluster
Genes + condiciones "verde"

- Los métodos de clustering agrupan **genes** con **patrones de expresión similares** en **todas** las condiciones
- Los métodos de biclustering agrupan **genes** con **patrones de expresión similares** en un **subconjunto** de condiciones

Análisis exploratorio: Análisis de componentes principales (PCA)




Objetivo: reducir la dimensionalidad preservando la mayor variabilidad posible.


- Transforma miles de genes en componentes principales (combinaciones lineales).
- Las primeras 2–3 componentes suelen explicar gran parte de la variabilidad.
- Permite visualizar los datos en 2D o 3D.

Aplicación:

- Detectar agrupamientos de muestras
- Observar tendencias o separaciones entre condiciones



Las 2 primeras componentes para la expresión de 8 genes en pacientes control (Cx) y pacientes con síndrome de Down (DSx)



Las 3 primeras componentes (asociadas a neurología, hematopoiesis y malignidad) para la expresión de 5372 genes en diferentes tejidos humanos. Se identifican 6 grupos.