



Bioinformática. Ingeniería Biomédica

Examen final convocatoria ordinaria. 13 de Junio de 2025

Instrucciones para la entrega del ejercicio:

- Debes subir el ejercicio completo en un único archivo PDF. El documento debe mantener el orden original de las preguntas, e incluir tanto las salidas como el código en R que hayas utilizado para responder.
- Utiliza únicamente las instrucciones de R estrictamente necesarias para resolver cada cuestión. El uso de funciones genéricas, innecesarias o no específicas será penalizado.
- Todas las respuestas deben estar comentadas y justificadas, explicando claramente el razonamiento seguido. El código en R también debe estar debidamente comentado, indicando la función de cada línea o bloque.

Ejercicio 1 (4 puntos)

La retinopatía diabética es una de las principales causas de pérdida de visión en personas con diabetes. Su progresión involucra una compleja interacción de procesos celulares y moleculares que afectan a distintos tipos de células de la retina. Con el objetivo de investigar los mecanismos moleculares subyacentes a esta enfermedad, se ha llevado a cabo un estudio de expresión génica en retina humana mediante tecnología de RNA-seq. En este experimento se analizaron muestras retinianas *post-mortem* procedentes de 35 donantes humanos, clasificados en cuatro grupos clínicos: individuos sanos sin diabetes (**Control**), pacientes con diabetes pero sin signos de retinopatía (**Diabetic**), pacientes con retinopatía diabética no proliferativa (NPDR), y pacientes con retinopatía proliferativa con edema macular (PDR). Para cada donante se registraron variables fenotípicas adicionales como el sexo y la edad.

La información está disponible en el archivo `Ej1.RData` que podéis leer utilizando la función `load()`.

```
load("datos/Ej1.RData")
```

El archivo contiene dos objetos de tipo `data.frame`:

- `rawCount`: matriz de conteo.
- `phenoData`: las variables fenotípicas de cada muestra, incluyendo el identificador (`sample`), el código GEO (`geo`), el sexo (`gender`), la edad (`age`) y el grupo clínico (`disease_group`).

- (a) (1 punto) Comprueba la estructura de los objetos `rawCount` y `phenoData`. ¿Cuántos genes se han cuantificado y cómo se distribuyen las muestras entre los distintos grupos clínicos? ¿Cuántos genes se han expresado en alguna de las muestras? Utiliza algún método para normalizar los datos y justifica por qué es necesaria esta transformación. Utiliza alguna herramienta gráfica que permita comparar los datos antes y después de la normalización.
- (b) (1 punto) Considerando dos grupos clínicos: con y sin retinopatía diabética (`With_DR` y `No_DR`, respectivamente), realiza un análisis de expresión diferencial entre esos grupos teniendo en cuenta el efecto del sexo.

Una vez hecho el análisis, responde a las siguientes cuestiones:

- (b1) (0.5 puntos) Comenta brevemente el histograma de los p-valores sin ajustar por comparaciones múltiples. ¿Te parece que este ajuste sería útil en este caso?
- (b2) (0.5 puntos) Cuando controlamos la tasa FDR a nivel 0.1, es decir tras un ajuste por comparaciones múltiples, ¿cuántos genes están diferencialmente expresados? A partir del histograma obtenido en (b1), ¿era esperable este resultado?
- (c) (1 punto) Construye un Volcano plot con los resultados obtenidos en el análisis de expresión diferencial que has realizado en (b). ¿Cuántos genes hay estadísticamente significativos a nivel 0.1 con valor absoluto de *log Fold Change* mayor que 2?

Ejercicio 2 (3 puntos)

Se pretende obtener un modelo de clasificación utilizando el algoritmo *random forest* que permita predecir si un individuo con diabetes (`disease_group = Diabetes`) desarrollará retinopatía diabética no proliferativa (`disease_group = NPDR`) a partir de la expresión de una muestra de 50 genes seleccionados aleatoriamente:

```
rawCount.class<-rawCount[rowSums(rawCount==0)==0,] # genes con expresión en todas las muestras

set.seed(13549)
gen.sample<-sample(1:nrow(rawCount.class),size=50)
```

- (a) (0.5 puntos) Construye un `data.frame` con los valores de expresión en conteo bruto, transformados logarítmicamente, para los 50 genes seleccionados, incluyendo únicamente las muestras correspondientes a los grupos de interés. El `data.frame` debe tener una fila por muestra y una columna por gen, además de una columna con la clase (`group`).
- (b) (1 punto) Utiliza el algoritmo *random forest* para ajustar un modelo de clasificación con el conjunto de datos generado. Utiliza todas las muestras como conjunto de entrenamiento. Explica el resultado obtenido. ¿Te parece una buena regla de validación?
- (c) (0.5 puntos) Utilizando el modelo de *random forest* ajustado previamente, identifica los genes que resultan más informativos para predecir la aparición de retinopatía diabética no proliferativa. ¿Qué gen o genes seleccionarías como los más relevantes y por qué?
- (d) (1 punto) Si no tuviéramos información previa sobre las clases de los individuos, ¿cuántos grupos identificaríamos de manera óptima aplicando el algoritmo de *k-medias* sobre las muestras de expresión? Lleva a cabo el agrupamiento y representa el resultado gráficamente. La agrupación obtenida, ¿tiene algo que ver con si el paciente tiene o no retinopatía diabética?

Ejercicio 3 (3 puntos)

Las siguientes dos líneas representan las secuencias de fragmentos de dos proteínas particulares de humano.

```
seq1 <- "GSAQVKGHGKKVADALTNAVAHVDDMPNALSALSDLHAHKL"  
seq2 <- "GNPKVKAHGKKVLGAFSDGTFATLSLHCDKL"
```

- (a) (1 punto) Utiliza la matriz de sustitución 'PAM30' para llevar a cabo un alineamiento global de estas dos secuencias, con penalizaciones de -4 y -2 para la creación de un nuevo *gap* y para la extensión de uno existente, respectivamente. Reporta el alineamiento obtenido junto con su puntuación.
- (b) (0.5 puntos) Repite el apartado (a) modificando las penalizaciones para los huecos, -20 y -5 para la creación de un nuevo *gap* y para la extensión de uno existente, respectivamente. Reporta el alineamiento obtenido junto con su puntuación.
- (c) (0.5 puntos) Comenta brevemente las diferencias entre los alineamientos obtenidos en (a) y (b) y explica el por qué de estas diferencias.
- (d) (1 punto) ¿Son los alineamientos obtenidos en (a) y (b) significativos? Utiliza el modelo multinomial para llevar a cabo estos contrastes.